

**Analisis Perbandingan Model *Machine Learning* untuk Prediksi
Diabetes Mellitus Tipe 2 dengan Pendekatan *Explainable AI***

Tugas Akhir

**diajukan untuk memenuhi salah satu syarat memperoleh gelar sarjana
pada Program Studi Sains Data
Direktorat Kampus Purwokerto
Universitas Telkom**

2311110037

Ratih Ambara Sukma Kurnilia



**Program Studi Sarjana Sains Data
Direktorat Kampus Purwokerto
Universitas Telkom**

Purwokerto

2026

LEMBAR PENGESAHAN

**Analisis Perbandingan Model *Machine Learning* untuk Prediksi
Diabetes Mellitus Tipe 2 dengan Pendekatan *Explainable AI***

***Comparative Analysis of Machine Learning Models for Predicting Type 2
Diabetes Mellitus with an Explainable AI Approach***

2311110037

Ratih Ambara Sukma Kurnilia

Usulan Penelitian Tugas Akhir telah disetujui pada tanggal
19 Mei 2026

Menyetujui

Pembimbing I,

Pembimbing II,

Aditya Dwi Putro W, S.Kom., M.Kom.
NIP: 17930052

Lisda, S.Kom., M.Kom.
NIP: 24990008

Ketua Program Studi
Sarjana Sains Data,

Sudianto, S.Pd., M.Kom.
NIP: 24930008

LEMBAR ORISINALITAS

Dengan ini saya, Ratih Ambara Sukma Kurnilia, menyatakan sesungguhnya bahwa Tugas Akhir saya dengan judul Analisis Perbandingan Model *Machine Learning* untuk Prediksi Diabetes Mellitus Tipe 2 dengan Pendekatan *Explainable AI* beserta dengan seluruh isinya merupakan hasil karya saya sendiri, dengan tidak melakukan penjiplakan yang tidak sesuai dengan etika keilmuan yang berlaku dengan masyarakat keilmuan, serta produk dari tugas akhir ini bukan merupakan hasil dari *Generative AI*. Saya siap menanggung risiko/sanksi yang diberikan jika di kemudian hari ditemukan pelanggaran terhadap etika keilmuan dalam Laporan Tugas Akhir, atau jika ada klaim dari pihak lain terhadap keaslian karya.

Purwokerto, 19 Mei 2026

Yang menyatakan

Ratih Ambara Sukma Kurnilia

NIM: 2311110037

ABSTRAK

Diabetes Mellitus Tipe 2 (T2DM) merupakan penyakit kronis dengan prevalensi yang terus meningkat dan memerlukan deteksi dini untuk mencegah komplikasi. Penelitian ini bertujuan untuk menganalisis perbandingan performa algoritma *machine learning* dalam memprediksi T2DM berbasis data *Electronic Health Records*. Dataset yang digunakan meliputi data demografis, riwayat diagnosis, penggunaan obat, serta hasil pemeriksaan klinis yang diintegrasikan menggunakan atribut *PatientGuid*. Metode penelitian menggunakan kerangka kerja OSEMN yang mencakup perolehan data, pembersihan dan penyiapan data, eksplorasi data, pemodelan, serta interpretasi hasil. Pada tahap *preprocessing* dilakukan penanganan *missing values*, *encoding* variabel kategorikal, serta standarisasi fitur numerik. Data kemudian dibagi menjadi data latih dan data uji menggunakan *stratified split* untuk menjaga distribusi kelas. Model yang dibandingkan terdiri dari algoritma *baseline* yaitu *Logistic Regression*, *Support Vector Machine*, dan *K-Nearest Neighbors*, serta algoritma *boosting* yaitu *Gradient Boosting*, *XGBoost*, dan *LightGBM*. Perbandingan performa model dilakukan untuk mengidentifikasi algoritma terbaik dalam memprediksi T2DM, dengan optimasi *hyperparameter* menggunakan *Optuna*. Model dengan performa terbaik selanjutnya akan diinterpretasikan menggunakan pendekatan *Explainable Artificial Intelligence* dengan metode *SHAP* untuk memberikan pemahaman mengenai kontribusi fitur dalam proses prediksi.

Kata Kunci: diabetes mellitus tipe 2, *machine learning*, *electronic health records*, klasifikasi, prediksi, *optuna*

ABSTRACT

Type 2 Diabetes Mellitus (T2DM) is a chronic disease with increasing prevalence and requires early detection to prevent complications. This study aims to analyze the comparative performance of machine learning algorithms in predicting T2DM based on Electronic Health Records data. The dataset includes patient demographics, diagnosis history, medication usage, and clinical measurements, which are integrated using the PatientGuid attribute. The research method follows the OSEMN framework, including data acquisition, data cleaning and preparation, data exploration, modeling, and result interpretation. In the preprocessing stage, missing values are handled, categorical variables are encoded, and numerical features are standardized. The dataset is then divided into training and testing sets using a stratified split to maintain class distribution. The models compared in this study include baseline algorithms, namely Logistic Regression, Support Vector Machine, and K-Nearest Neighbors, as well as boosting algorithms, including Gradient Boosting, XGBoost, and LightGBM. A comparative analysis is conducted to identify the best-performing algorithm for T2DM prediction, with hyperparameter optimization performed using the Optuna framework. The best-performing model will be further interpreted using Explainable Artificial Intelligence with the SHAP method to provide insights into feature contributions in the prediction process.

Keywords: *type 2 diabetes mellitus, machine learning, electronic health records, classification, prediction, optuna*

KATA PENGANTAR

Puji dan syukur penulis panjatkan ke hadirat Tuhan Yang Maha Esa atas segala rahmat dan karunia-Nya sehingga penulis dapat menyelesaikan proposal tugas akhir ini dengan baik. Proposal ini disusun sebagai salah satu syarat untuk menyelesaikan pendidikan pada Program Studi yang penulis tempuh.

Penulisan proposal tugas akhir ini bertujuan untuk mengkaji dan menganalisis topik yang telah dipilih oleh penulis, serta sebagai langkah awal dalam penyusunan tugas akhir yang lebih komprehensif. Penulis menyadari bahwa dalam proses penyusunan proposal ini tidak terlepas dari bantuan, bimbingan, serta dukungan dari berbagai pihak. Oleh karena itu, pada kesempatan ini penulis ingin menyampaikan ucapan terima kasih kepada:

1. Allah SWT dan Nabi Muhammad SAW atas segala rahmat dan petunjuk-Nya.
2. Kedua orang tua tercinta, Ayah dan Ibu, yang senantiasa memberikan dukungan moral, doa, serta dukungan finansial.
3. Bapak Sudianto, S.Pd., M.Kom. selaku Ketua Program Studi Sains Data yang telah memberikan arahan selama masa perkuliahan.
4. Bapak Aditya Dwi Putro W, S.Kom., M.Kom. dan Lisda, S.Kom., M.Kom. selaku dosen pembimbing yang telah memberikan bimbingan, arahan, serta masukan selama proses penyusunan skripsi.
5. Semua pihak yang tidak dapat disebutkan satu per satu yang telah membantu dalam penyusunan skripsi ini.

Purwokerto, 19 Mei 2026

Ratih Ambara Sukma Kurnilia

DAFTAR ISI

LEMBAR PENGESAHAN	ii
LEMBAR ORISINALITAS	iii
ABSTRAK	iv
ABSTRACT	v
KATA PENGANTAR.....	vi
DAFTAR ISI.....	vii
DAFTAR GAMBAR.....	ix
DAFTAR TABEL	x
DAFTAR LAMPIRAN	xi
BAB I PENDAHULUAN.....	12
1.1. Latar Belakang	12
1.2. Rumusan Masalah	15
1.3. Tujuan Penelitian	16
1.4. Manfaat Penelitian	16
1.5. Batasan Masalah.....	17
1.6. Jadwal Penelitian.....	18
BAB II LANDASAN TEORI	19
2.1. Tinjauan Pustaka.....	19
2.2. Landasan Teori.....	31
2.2.1. Diabetes Mellitus Tipe 2	31
2.2.2. Machine Learning dan Klasifikasi	32
2.2.3. Normalisasi Data.....	33
2.2.4. Logistic Regression.....	34

2.2.5. SVM.....	35
2.2.6. KNN.....	36
2.2.7. Gradient Boosting	36
2.2.8. XGBoost.....	37
2.2.9. LightGBM.....	38
2.2.10. Optuna Framework	38
2.2.11. Metrik Evaluasi	40
2.2.12. Explainable AI	43
BAB III METODE PENELITIAN	45
3.1. Subjek dan Objek Penelitian	45
3.2. Alat dan Bahan Penelitian.....	46
3.2.1. Alat Penelitian.....	46
3.2.2. Bahan Penelitian	46
3.3. Diagram Alir Penelitian	47
3.3.1. OBTAIN (Perolehan Data)	48
3.3.2. SCRUB (Pembersihan dan Penyiapan Data)	49
3.3.3. EXPLORE (Eksplorasi Data).....	51
3.3.4. MODEL (Pemodelan)	53
3.3.5. INTERPRET (Evaluasi dan Interpretasi Model)	57
DAFTAR PUSTAKA.....	60
LAMPIRAN.....	65

DAFTAR GAMBAR

Gambar 2. 1 Perbandingan Karakteristik Algoritma <i>Machine learning</i>	33
Gambar 2. 2 <i>Confusion matrix</i> dan Performance Metrics.....	40
Gambar 2. 3 <i>ROC Curve</i> dan <i>AUC</i>	42
Gambar 2. 4 <i>SHAP</i> Visualizations	43
Gambar 3. 1 Diagram Alir Penelitian	47
Gambar 3. 2 <i>Machine learning</i> Pipeline untuk Prediksi Diabetes	54

DAFTAR TABEL

Tabel 1. 1 Jadwal Kegiatan	18
Tabel 2. 1 Ringkasan Penelitian Terdahulu	22
Tabel 3. 1 Struktur Dataset.....	48

DAFTAR LAMPIRAN

Lampiran 1. Deskripsi Dataset <i>patient.csv</i>	62
Lampiran 2. Deskripsi Dataset <i>diagnosis.csv</i>	62
Lampiran 3. Deskripsi Dataset <i>medication.csv</i>	64
Lampiran 4. Deskripsi Dataset <i>transcript.csv</i>	64

BAB I

PENDAHULUAN

1.1. Latar Belakang

Perkembangan teknologi *machine learning* dalam beberapa tahun terakhir semakin pesat dan sudah banyak digunakan di berbagai bidang, seperti industri, keuangan, dan juga kesehatan. *Machine learning* memungkinkan komputer untuk mempelajari pola dari data dan menghasilkan prediksi tanpa harus diprogram secara detail. Dengan semakin banyaknya data yang tersedia serta meningkatnya kemampuan komputasi, penggunaan *machine learning* menjadi semakin luas dan berkembang [1].

Di bidang kesehatan, *machine learning* mulai banyak dimanfaatkan untuk membantu proses diagnosis dan prediksi penyakit. Hal ini karena *machine learning* mampu mengolah data dalam jumlah besar dan menemukan pola yang sulit dikenali secara manual [2]. Salah satu jenis data yang sering digunakan adalah data rekam medis elektronik atau *Electronic Health Records (EHR)*. Data ini berisi berbagai informasi pasien, seperti data demografi, riwayat penyakit, hasil pemeriksaan, dan data klinis lainnya [3]. Dengan memanfaatkan data tersebut, model *machine learning* dapat digunakan untuk membantu memprediksi risiko suatu penyakit secara lebih cepat dan efisien [4], [5].

Salah satu penyakit yang banyak diteliti menggunakan *machine learning* adalah Diabetes Mellitus Tipe 2 (T2DM). T2DM merupakan penyakit kronis yang terjadi akibat gangguan metabolisme glukosa dalam tubuh, yang disebabkan oleh resistensi insulin dan penurunan fungsi sel beta pankreas [6]. Berdasarkan data dari World Health Organization, jumlah penderita diabetes terus meningkat dari tahun ke tahun dan telah mencapai lebih dari 830 juta orang di seluruh dunia [7]. Penyakit ini juga dapat menimbulkan berbagai komplikasi serius, seperti penyakit jantung, gangguan ginjal, dan kerusakan saraf [8]. Selain itu, beberapa penelitian juga menunjukkan adanya faktor risiko lain yang berkaitan dengan kondisi metabolik tubuh [9].

Deteksi dini terhadap T2DM sangat penting agar penyakit dapat ditangani lebih cepat dan risiko komplikasi dapat dikurangi. Namun, metode konvensional seperti pemeriksaan kadar gula darah masih memiliki beberapa keterbatasan, misalnya membutuhkan biaya, waktu, dan akses ke fasilitas kesehatan. Selain itu, pemeriksaan tersebut biasanya dilakukan setelah muncul gejala, sehingga kurang efektif untuk deteksi dini. Oleh karena itu, diperlukan metode lain yang lebih cepat dan efisien untuk memprediksi risiko diabetes.

Berbagai algoritma *machine learning* telah digunakan untuk memprediksi diabetes. Beberapa algoritma *baseline* seperti *Logistic Regression*, *Support Vector Machine (SVM)*, dan *K-Nearest Neighbors (KNN)* merupakan metode klasifikasi yang relatif sederhana dan sering digunakan sebagai model awal [10]. *Logistic Regression* merupakan model linear berbasis probabilitas, *SVM* bekerja dengan mencari hyperplane optimal, sedangkan *KNN* melakukan klasifikasi berbasis jarak [11]. Penelitian yang dilakukan oleh Kurniawan et al. [10] membandingkan ketiga algoritma tersebut dan menunjukkan bahwa *Logistic Regression* mencapai akurasi sekitar 75%, *SVM* sebesar 74%, dan *KNN* sebesar 71% pada dataset diabetes. Hasil tersebut menunjukkan bahwa algoritma *baseline* cukup baik sebagai model awal, namun memiliki keterbatasan dalam menangani hubungan yang kompleks dan non-linear pada data kesehatan.

Untuk mengatasi hal tersebut, digunakan metode yang lebih kompleks seperti *boosting*, yaitu *Gradient Boosting*, *XGBoost*, dan *LightGBM*. Metode *boosting* merupakan teknik *ensemble learning* yang membangun model secara bertahap dengan memperbaiki kesalahan model sebelumnya [12]. *Gradient Boosting* bekerja dengan meminimalkan fungsi *loss* secara iteratif, *XGBoost* merupakan pengembangan dengan tambahan regularisasi dan efisiensi komputasi, sedangkan *LightGBM* menggunakan pendekatan *leaf-wise* untuk meningkatkan kecepatan pelatihan [13]. Penelitian oleh Tuppad et al. [14] menunjukkan bahwa *LightGBM* mampu mencapai akurasi 95.20%, lebih tinggi dibandingkan *Logistic Regression* yang hanya mencapai 75.20%. Selain itu, penelitian oleh Hasan et al. [15] menunjukkan bahwa model berbasis *XGBoost* mampu mencapai akurasi 92.50% dengan *ROC-AUC* sebesar 0.975. Penelitian lain oleh Elseddawy et al. [16] juga

menunjukkan bahwa *Gradient Boosting* dapat mencapai akurasi hingga 97%. Hasil ini menunjukkan bahwa metode *boosting* memiliki performa yang lebih baik dibandingkan algoritma *baseline* dalam menangani data yang kompleks.

Meskipun demikian, algoritma *baseline* memiliki kelemahan dalam menangani hubungan non-linear dan cenderung bias pada data yang tidak seimbang [10]. Di sisi lain, metode *boosting* juga memiliki tantangan, seperti risiko *overfitting* dan sensitivitas terhadap pemilihan *hyperparameter* [17]. Pemilihan parameter yang tidak tepat dapat menyebabkan model tidak optimal atau bahkan menurun performanya. Oleh karena itu, proses *hyperparameter tuning* menjadi sangat penting untuk meningkatkan performa model. Penelitian oleh Peng et al. [17] menunjukkan bahwa penggunaan *Optuna* sebagai metode optimasi *hyperparameter* dapat meningkatkan akurasi model dari sekitar 85% menjadi 95.45%. Selain itu, penelitian oleh Maryanti et al. [18] juga menunjukkan bahwa penggunaan *Optuna* mampu menghasilkan akurasi sebesar 93.27% pada kasus klasifikasi lainnya. Hal ini menunjukkan bahwa *Optuna* lebih efektif dibandingkan metode konvensional seperti *grid search* karena mampu mengeksplorasi ruang parameter secara lebih efisien.

Beberapa penelitian sebelumnya telah menunjukkan bahwa *machine learning* dapat digunakan untuk memprediksi diabetes dengan hasil yang cukup baik. Penelitian oleh Siana et al. [19] menunjukkan bahwa model berbasis kecerdasan buatan mampu memprediksi risiko diabetes secara efektif dengan akurasi tertinggi 79%. Penelitian oleh Haixiang et al. [20] juga berhasil memprediksi komplikasi diabetes berupa *diabetic foot* menggunakan model *machine learning* dengan akurasi sebesar 95% dan sensitivitas sebesar 92.86%. Selain itu, penelitian oleh Nayan et al. [21] menunjukkan bahwa model *ensemble* mampu mencapai *AUC* sebesar 0.868, lebih tinggi dibandingkan model tunggal. Penelitian oleh El Massari et al. [22] juga menunjukkan bahwa penggunaan *feature engineering* dan optimasi model mampu meningkatkan akurasi hingga 94%.

Berdasarkan berbagai penelitian tersebut, terlihat bahwa penggunaan algoritma *boosting* dan teknik optimasi memberikan peningkatan performa yang signifikan. Namun, penelitian terdahulu menggunakan pendekatan *hyperparameter*

tuning yang beragam, seperti *grid search*, *random search*, maupun tanpa *tuning* sistematis [10], [22]. Sementara itu, penggunaan *Optuna* sebagai metode optimasi yang lebih efisien masih belum banyak diterapkan secara komprehensif pada kasus prediksi diabetes, terutama dalam kombinasi dengan perbandingan algoritma baseline dan boosting secara sistematis.

Di sisi lain, dalam bidang kesehatan, hasil prediksi tidak hanya harus akurat tetapi juga harus dapat dipahami. Oleh karena itu, diperlukan pendekatan *Explainable Artificial Intelligence (XAI)* untuk membantu menjelaskan hasil model [23]. Salah satu metode yang sering digunakan adalah *SHAP*, yang dapat menunjukkan kontribusi masing-masing fitur terhadap hasil prediksi [15], [24]. Namun, metode ini juga memiliki beberapa keterbatasan yang perlu diperhatikan dalam interpretasi hasil [25].

Berdasarkan permasalahan tersebut, penelitian ini akan dilakukan untuk membandingkan performa algoritma *machine learning baseline* dan metode *boosting* dalam memprediksi Diabetes Mellitus Tipe 2 menggunakan data *EHR*. Selain itu, penelitian ini juga menerapkan *hyperparameter tuning* untuk meningkatkan performa model. Setelah itu, model terbaik akan dianalisis menggunakan metode *SHAP* untuk melihat interpretasi hasilnya. Model yang dihasilkan juga akan dibangun dalam bentuk sistem sederhana agar dapat digunakan sebagai pendukung pengambilan keputusan. Dengan demikian, diharapkan penelitian ini dapat menghasilkan model yang tidak hanya akurat, tetapi juga dapat dipahami dan digunakan dalam bidang kesehatan.

1.2. Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, maka rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana membangun model *machine learning* untuk prediksi Diabetes Mellitus Tipe 2 menggunakan data *EHR* dengan menerapkan algoritma *baseline* dan algoritma berbasis *boosting*?

2. Bagaimana perbandingan performa antara algoritma *machine learning* tradisional sebagai model *baseline* dan algoritma berbasis *boosting* dalam memprediksi Diabetes Mellitus Tipe 2 berdasarkan data *EHR*?
3. Bagaimana pengaruh penerapan *hyperparameter tuning* terhadap peningkatan performa model *machine learning*, baik pada algoritma tradisional maupun algoritma berbasis *boosting*?
4. Algoritma *machine learning* apa yang memberikan performa terbaik dalam prediksi Diabetes Mellitus Tipe 2, serta bagaimana hasil prediksi dari model terbaik tersebut dapat diinterpretasikan menggunakan pendekatan *XAI* untuk mengidentifikasi fitur-fitur yang berpengaruh?

1.3. Tujuan Penelitian

Berdasarkan rumusan masalah yang telah ditetapkan, maka tujuan dari penelitian ini adalah sebagai berikut:

1. Membangun model *machine learning* untuk prediksi Diabetes Mellitus Tipe 2 menggunakan data *EHR* dengan menerapkan algoritma *baseline* dan algoritma berbasis *boosting*.
2. Menganalisis perbandingan performa antara algoritma *machine learning* tradisional sebagai model *baseline* dan algoritma berbasis *boosting* dalam memprediksi Diabetes Mellitus Tipe 2 berdasarkan data *EHR*.
3. Menganalisis pengaruh penerapan *hyperparameter tuning* terhadap peningkatan performa model *machine learning*, baik pada algoritma tradisional maupun algoritma berbasis *boosting*.
4. Menentukan algoritma *machine learning* yang memberikan performa terbaik dalam prediksi Diabetes Mellitus Tipe 2 serta menginterpretasikan hasil prediksi model menggunakan pendekatan *Explainable AI* untuk mengidentifikasi fitur-fitur yang berpengaruh.

1.4. Manfaat Penelitian

Manfaat penelitian ini menjelaskan kontribusi yang dapat diperoleh apabila permasalahan dalam penelitian ini berhasil diselesaikan. Manfaat tersebut ditujukan

bagi pihak-pihak yang berkaitan dengan pemanfaatan hasil penelitian, baik secara akademis maupun praktis.

Penelitian ini diharapkan dapat memberikan manfaat bagi berbagai pihak sebagai berikut:

1. Bagi tenaga medis dan praktisi kesehatan

Hasil penelitian ini diharapkan dapat membantu dalam proses pengambilan keputusan klinis, khususnya dalam mendeteksi risiko Diabetes Mellitus Tipe 2 secara lebih dini melalui pemanfaatan model prediksi berbasis *machine learning* yang lebih akurat dan objektif.

2. Bagi pengembang sistem dan organisasi di bidang kesehatan

Penelitian ini dapat menjadi acuan dalam pengembangan sistem pendukung keputusan berbasis data *EHR*, sehingga dapat meningkatkan efisiensi dan efektivitas dalam pengelolaan data pasien serta prediksi risiko penyakit.

3. Bagi peneliti dan akademisi

Penelitian ini diharapkan dapat menjadi referensi dalam pengembangan penelitian selanjutnya, khususnya yang berkaitan dengan perbandingan algoritma *machine learning* tradisional dan metode berbasis *boosting*, penerapan *hyperparameter tuning*, serta penggunaan *XAI* dalam meningkatkan interpretabilitas model prediksi.

1.5. Batasan Masalah

Agar penelitian ini lebih terarah dan sesuai dengan tujuan yang ditetapkan, maka batasan masalah dalam penelitian ini adalah sebagai berikut:

1. Penelitian ini menggunakan data *EHR* yang berfokus pada data terstruktur, tanpa melibatkan data citra medis maupun data tidak terstruktur lainnya.
2. Penelitian difokuskan pada prediksi Diabetes Mellitus Tipe 2 sebagai variabel target, tanpa membahas jenis diabetes lain maupun penyakit penyerta secara mendalam.
3. Model yang digunakan terbatas pada beberapa algoritma *machine learning* tradisional sebagai *baseline* dan algoritma berbasis *boosting* sebagai

pembandingan utama, dengan peningkatan performa melalui *hyperparameter tuning*.

4. Evaluasi model dilakukan menggunakan metrik klasifikasi, serta interpretasi hasil prediksi dilakukan menggunakan pendekatan *XAI* dengan metode *SHAP* yang diterapkan pada model dengan performa terbaik untuk mengidentifikasi fitur-fitur yang berpengaruh.

1.6. Jadwal Penelitian

Untuk merealisasikan tujuan penelitian dan rencana kegiatan yang telah disusun, diperlukan penjadwalan yang sistematis agar setiap tahapan dapat terlaksana secara efektif dan efisien. Jadwal kegiatan berikut ini mencakup keseluruhan proses pelaksanaan Tugas Akhir, mulai dari tahap persiapan hingga penyusunan laporan akhir:

Tabel 1. 1 Jadwal Kegiatan

Kegiatan	Bulan					
	1	2	3	4	5	6
Kajian Pustaka						
Pengembangan Metadologi						
Pengumpulan Data						
Implementasi Model						
Uji Coba						
Analisa Hasil						
Penulisan Laporan						

BAB II

LANDASAN TEORI

2.1. Tinjauan Pustaka

Penelitian terkait prediksi Diabetes Mellitus Tipe 2 (T2DM) menggunakan *machine learning* telah banyak dilakukan dengan berbagai pendekatan. Secara umum, penelitian-penelitian tersebut berfokus pada peningkatan akurasi model, pemilihan algoritma yang tepat, serta bagaimana model dapat digunakan secara lebih efektif dalam konteks kesehatan.

Beberapa penelitian awal fokus pada perbandingan algoritma *machine learning*. Penelitian [10] membandingkan *Logistic Regression*, *Random Forest*, *Support Vector Machine (SVM)*, dan *K-Nearest Neighbors (KNN)* dengan menerapkan *SMOTE* untuk mengatasi ketidakseimbangan data. Hasilnya menunjukkan bahwa *Random Forest* memiliki performa terbaik dengan *F1-score* sebesar 96,92% dan *AUC* 99,70%. Meskipun *SVM* menunjukkan performa yang baik, waktu komputasi yang lebih besar menjadi kendala. Temuan ini mengindikasikan bahwa metode *ensemble* lebih unggul dibandingkan dengan algoritma tunggal. Hal ini juga diperkuat oleh penelitian [14] yang membandingkan beberapa algoritma seperti *Logistic Regression*, *Decision Tree*, *Random Forest*, *Gradient Boosting*, *XGBoost*, dan *LightGBM*. Hasil penelitian menunjukkan bahwa *LightGBM* memberikan akurasi tertinggi sebesar 95,20%. Temuan ini semakin memperkuat bahwa algoritma berbasis *boosting* mampu menangani data yang kompleks dengan lebih baik.

Selain pemilihan algoritma, optimasi model juga berperan penting dalam meningkatkan performa. Penelitian [22] menunjukkan bahwa penggunaan *feature engineering* dan *hyperparameter tuning* dapat meningkatkan performa model secara signifikan. Dengan menggunakan *RFECV* dan *GridSearchCV*, model *XGBoost* berhasil mencapai akurasi sebesar 94%, lebih tinggi dibandingkan model lainnya. Hal ini menunjukkan bahwa kualitas fitur dan parameter sangat berpengaruh terhadap hasil prediksi. Penggunaan metode *ensemble* juga banyak diteliti karena kemampuannya dalam meningkatkan performa model. Penelitian

[26] menunjukkan bahwa metode *ensemble* seperti *Bagging*, *Boosting*, dan *Stacking* mampu mencapai akurasi hingga 97%, lebih tinggi dibandingkan model individual. Hal ini terjadi karena *ensemble* menggabungkan kelebihan dari beberapa model sehingga menghasilkan prediksi yang lebih stabil.

Penelitian lain [27] mengombinasikan *feature selection* dengan algoritma *boosting* seperti *LightGBM*. Hasilnya menunjukkan akurasi sebesar 85,16% dan *F1-score* sebesar 85,41%, dengan jumlah fitur yang lebih sedikit serta waktu pelatihan yang lebih efisien. Hal ini menunjukkan bahwa pemilihan fitur yang tepat dapat meningkatkan efisiensi tanpa mengurangi performa model. Dalam hal optimasi model, penelitian [28] mengembangkan metode berbasis *ensemble* yang mampu mencapai akurasi hingga 99%, dengan *precision* 98,5% dan *recall* 99%. Hasil ini menunjukkan bahwa kombinasi antara optimasi parameter dan *ensemble learning* dapat menghasilkan model dengan performa yang sangat tinggi.

Selain itu, permasalahan ketidakseimbangan data juga menjadi perhatian dalam beberapa penelitian. Penelitian [29] mengombinasikan *SMOTE* dan *Near Miss* serta menerapkan *Explainable AI*. Hasilnya menunjukkan bahwa model *XGBoost* dengan *SMOTE* mampu mencapai akurasi 99% dan *F1-score* 1,00. Penelitian [16] juga menunjukkan bahwa penggunaan *SMOTE* dapat meningkatkan performa model, dengan nilai *AUC* mencapai 0,89 dan akurasi sebesar 90,2%. Hal ini menunjukkan bahwa *preprocessing* data memiliki peran penting dalam meningkatkan kualitas model.

Di sisi lain, interpretabilitas model juga menjadi aspek penting, terutama dalam bidang kesehatan. Penelitian [30] menunjukkan bahwa pendekatan *interpretable machine learning* dapat membantu mengidentifikasi faktor-faktor penting dalam diagnosis diabetes. Sementara itu, penelitian [15] menggabungkan *AutoML* dan *Explainable AI* untuk menghasilkan model yang tidak hanya akurat tetapi juga transparan.

Secara keseluruhan, berbagai penelitian ini menunjukkan bahwa *machine learning* memiliki potensi besar dalam prediksi diabetes. Namun, sebagian besar penelitian masih berfokus pada satu aspek tertentu, seperti pemilihan algoritma, optimasi model, atau interpretabilitas. Selain itu, perbandingan antara algoritma

baseline dan *boosting* dalam satu kerangka yang sama masih terbatas. Oleh karena itu, penelitian ini bertujuan untuk menggabungkan pendekatan-pendekatan tersebut, yaitu perbandingan algoritma, *hyperparameter tuning* menggunakan *Optuna*, serta penerapan *Explainable AI*, untuk menghasilkan model yang lebih akurat dan mudah dipahami.

Tabel 2. 1 Ringkasan Penelitian Terdahulu

No.	Judul dan Tahun	Pembahasan	Metode	Kelebihan dan Kekurangan	Perbedaan Penelitian
1	<i>Comparison of Logistic Regression, Random Forest, Support Vector Machine (SVM) and K-Nearest Neighbor (KNN) Algorithms in Diabetes Prediction, 2025 [10]</i>	Penelitian ini menunjukkan bahwa <i>Random Forest</i> mampu mencapai <i>F1-Score</i> sebesar 96.92% dengan <i>AUC</i> 99.70% pada dataset berukuran 100 ribu data, sehingga melampaui performa <i>Logistic Regression</i> yang sekitar 75%, <i>SVM</i> sebesar 74.4%, dan <i>KNN</i> sebesar 70.8%. Penerapan <i>SMOTE</i> berhasil menyeimbangkan data dengan meningkatkan jumlah sampel diabetes dari 15% menjadi distribusi seimbang 85K:85K. Hasil ini memberikan bukti empiris bahwa metode <i>ensemble</i> seperti <i>Random Forest</i> lebih unggul dibandingkan algoritma sederhana.	<i>Logistic Regression, Random Forest, SVM, K-Nearest Neighbors, 80:20 train-test split, 5-fold stratified cross-validation, SMOTE untuk class balancing</i>	Kelebihan: Evaluasi sistematis 4 algoritma klasik pada dataset besar (100K <i>records</i>), <i>SMOTE effectiveness</i> untuk <i>class imbalance</i> terbukti empiris, <i>RF</i> konsistensi tinggi. Kekurangan: Tanpa <i>hyperparameter tuning</i> sistematis, hanya <i>default parameters</i> , tanpa <i>XAI/interpretability analysis, feature importance analysis</i> <i>absent</i> , tidak ada <i>cross-dataset validation</i> .	Penelitian ini tidak hanya membandingkan algoritma <i>baseline</i> , tetapi juga melakukan perbandingan eksplisit antara algoritma <i>baseline</i> dan algoritma berbasis <i>boosting</i> dengan total enam algoritma. Selain itu, penelitian ini menerapkan <i>hyperparameter tuning</i> secara sistematis menggunakan <i>Optuna</i> serta mengintegrasikan

No.	Judul dan Tahun	Pembahasan	Metode	Kelebihan dan Kekurangan	Perbedaan Penelitian
					pendekatan <i>Explainable AI</i> menggunakan <i>SHAP</i> untuk meningkatkan interpretabilitas model.
2	<i>Diabetes Prediction Using Machine Learning with Feature Engineering and Hyperparameter Tuning</i> , 2024 [22]	Penelitian ini menunjukkan bahwa kombinasi <i>XGBoost</i> dengan <i>RFECV</i> mampu mencapai akurasi sebesar 94%. Teknik <i>RFECV</i> berhasil mengidentifikasi lima fitur utama, yaitu <i>Glucose</i> , <i>BMI</i> , <i>Age</i> , <i>DPF</i> , dan <i>Skin Thickness</i> . Selain itu, proses <i>feature engineering</i> terbukti mampu meningkatkan performa model sebesar 2–3% dibandingkan <i>baseline</i> . Penelitian ini menegaskan pentingnya kombinasi antara <i>feature engineering</i> dan <i>tuning</i> parameter.	5 <i>FSA techniques</i> (<i>SelectKBest</i> , <i>RFE</i> , <i>RFECV</i> , <i>Forward/Backward</i>), 5 <i>boosting algorithms</i> (<i>RF</i> , <i>GB</i> , <i>XGB</i> , <i>LGBM</i> , <i>CatBoost</i>), <i>GridSearchCV</i> <i>tuning</i> , <i>PIDD dataset only</i>	Kelebihan: <i>Komprehensif feature selection comparison</i> , <i>detail hyperparameter optimization</i> , <i>XGBoost superiority established</i> , <i>practical optimization guidance</i> . Kekurangan: <i>Single dataset (PIMA)</i> hanya, representasi demografis terbatas, tanpa <i>XAI</i> untuk <i>understanding decision mechanisms</i> , tanpa <i>baseline</i>	Penelitian ini menambahkan pendekatan <i>AutoML</i> melalui <i>Optuna</i> untuk eksplorasi <i>hyperparameter</i> yang lebih efisien. Selain itu, penelitian ini juga mencakup perbandingan algoritma <i>baseline</i> serta mengintegrasikan interpretabilitas menggunakan <i>SHAP</i>

No.	Judul dan Tahun	Pembahasan	Metode	Kelebihan dan Kekurangan	Perbedaan Penelitian
				<i>algorithms comparison</i> , akurasi 94% masih <i>below potential</i> dengan <i>deeper tuning</i> .	untuk memahami hubungan antar fitur.
3	Evaluasi Model <i>Ensemble Learning</i> pada Identifikasi Faktor Risiko Diabetes Mellitus, 2025 [26]	Hasil penelitian ini menunjukkan bahwa <i>Gradient Boosting</i> mencapai nilai R^2 sebesar 0.65 dan seluruh metode <i>ensemble</i> mampu mencapai akurasi sekitar 97%. Selain itu, ditemukan bahwa <i>Naïve Bayes</i> cenderung menghasilkan prediksi berlebih dengan <i>recall</i> tinggi namun <i>precision</i> rendah, sedangkan <i>Logistic Regression</i> dan <i>SVM</i> bersifat lebih konservatif dengan <i>recall</i> rendah dan <i>precision</i> tinggi. Temuan ini menunjukkan adanya <i>trade-off</i> antara <i>sensitivity</i> dan <i>specificity</i> yang sangat penting dalam konteks klinis.	5 base learners (NB, LR, SVM, DT, KNN) + 4 ensemble methods (Bagging, Boosting, Stacking, Voting), KNN Imputer, SMOTE balancing, PIMA dataset	Kelebihan: Komprehensif <i>ensemble comparison</i> , <i>sensitivity-specificity trade-off analysis</i> <i>valuable</i> untuk <i>clinical</i> , performa <i>robust</i> ~97%. Kekurangan: <i>Single dataset</i> (PIDD <i>specificity</i>), representasi demografis terbatas, tanpa <i>feature importance detail</i> , <i>clinical interpretability integration</i> minimal, tidak ada <i>baseline-</i>	Penelitian ini menambahkan perbandingan eksplisit antara algoritma <i>baseline</i> dan <i>boosting</i> , serta memperluas evaluasi pada dataset yang lebih beragam. Selain itu, penelitian ini juga memberikan interpretasi hasil model menggunakan <i>SHAP</i> untuk memahami kontribusi fitur secara lebih mendalam.

No.	Judul dan Tahun	Pembahasan	Metode	Kelebihan dan Kekurangan	Perbedaan Penelitian
				<i>boosting explicit comparison.</i>	
4	<i>Diabetes Prediction Using Feature Selection Algorithms and Boosting-Based Machine Learning Classifiers, 2025 [27]</i>	Penelitian ini menunjukkan bahwa <i>LightGBM</i> yang dikombinasikan dengan <i>Boruta</i> mampu mencapai akurasi 85.16%, <i>F1-score</i> 85.41%, dan <i>AUC</i> sebesar 0.9052 pada dataset <i>PIDD</i> . Selain itu, terjadi penurunan waktu pelatihan sebesar 54.96%, dari 0.0564 detik menjadi 0.0254 detik, dengan hanya menggunakan 5 dari 8 fitur. Validasi eksternal pada dataset <i>DiaHealth</i> menunjukkan performa yang sangat tinggi dengan akurasi 99.39% dan <i>recall</i> 100%, sehingga menunjukkan kemampuan generalisasi yang baik. Penelitian ini juga membuktikan bahwa pengurangan fitur dan penggunaan <i>XAI</i> dapat berjalan secara bersamaan.	5 <i>FSA</i> (<i>RFE</i> , <i>GWO</i> , <i>PSO</i> , <i>GA</i> , <i>Boruta</i>), 2 <i>boosting</i> (<i>XGB</i> , <i>LGBM</i>), 5-fold <i>CV</i> , 70:30 <i>split</i> , <i>SHAP</i> for <i>feature importance</i> , <i>PIDD</i> + <i>DiaHealth</i> validation	Kelebihan: <i>FSA</i> + <i>XAI</i> integration proven, strong external validation (99.39% <i>DiaHealth</i>), computational efficiency improved, feature reduction benefits established. Kekurangan: Limited to 2 datasets, <i>SHAP</i> only (depth minimal), tidak ada baseline comparison, no local patient-level interpretation.	Penelitian ini tetap menggunakan <i>SHAP</i> namun dikombinasikan dengan perbandingan algoritma baseline dan <i>boosting</i> . Selain itu, penelitian ini juga menekankan pada evaluasi model yang lebih sistematis serta pengembangan model yang lebih aplikatif.

No.	Judul dan Tahun	Pembahasan	Metode	Kelebihan dan Kekurangan	Perbedaan Penelitian
5	<i>An Optimized Diabetes Mellitus Detection Model for Improved Prediction of Accuracy and Clinical Decision-Making, 2024 [28]</i>	Penelitian ini menghasilkan model <i>GBM-DRU</i> dengan akurasi 99%, <i>precision</i> 98.5%, dan <i>recall</i> 99%, yang lebih unggul dibandingkan <i>Random Forest</i> (97%), <i>J48</i> (95%), <i>SVM</i> (80%), <i>XGBoost</i> (85%), <i>Naïve Bayes</i> (70%), dan <i>Soft Voting</i> (79%). Selain itu, hasil <i>cross-validation</i> menunjukkan stabilitas performa sebesar 95%. Meskipun demikian, performa yang sangat tinggi ini tidak diikuti dengan transparansi model maupun interpretasi klinis terhadap hasil prediksi.	<i>Gradient Boosting + Data Reduction Unit, aggressive feature engineering, ensemble stacking, 10-fold CV, undocumented dataset specifics</i>	Kelebihan: <i>Exceptional accuracy</i> (99%), <i>substantial margin vs baselines, cross-validation robustness</i> (95%). Kekurangan: Dataset <i>undocumented</i> (<i>reproducibility concern</i>), tanpa <i>XAI</i> untuk <i>understanding</i> , <i>potentially overfitted</i> (<i>limited external validation</i>), <i>generalizability unclear</i> , <i>no feature interpretation</i> .	Penelitian ini menekankan keseimbangan antara performa dan transparansi model. Selain itu, penelitian ini menggunakan pendekatan optimasi <i>hyperparameter</i> serta evaluasi yang lebih sistematis untuk memastikan model tidak <i>overfitting</i> .
6	<i>SMOTE Oversampling and Near Miss Undersampling</i>	Penelitian ini menunjukkan bahwa penggunaan <i>XGBoost</i> dengan penggunaan <i>SMOTE</i> mampu mencapai akurasi 99% dan <i>F1-score</i> sebesar 1.00,	10 <i>ML models</i> , <i>SMOTE oversampling</i> , <i>Near Miss</i>	Kelebihan: <i>Perfect F1-score</i> (1.00), <i>XAI-adoption link demonstrated, class</i>	Penelitian ini mengintegrasikan optimasi model menggunakan

No.	Judul dan Tahun	Pembahasan	Metode	Kelebihan dan Kekurangan	Perbedaan Penelitian
	<i>Based Diabetes Diagnosis from Imbalanced Dataset with XAI Visualization</i> , 2023 [29]	yang menunjukkan keseimbangan sempurna antara <i>precision</i> dan <i>recall</i> . Integrasi metode <i>XAI</i> seperti <i>SHAP</i> dan <i>LIME</i> juga terbukti meningkatkan kepercayaan pengguna dan keandalan model dalam konteks klinis. Temuan ini menegaskan bahwa transparansi model merupakan faktor penting dalam penerapan <i>machine learning</i> di bidang kesehatan.	<i>undersampling, XAI techniques (SHAP, LIME), imbalanced diabetes dataset</i>	<i>imbalance mitigation proven, clinical relevance emphasized.</i> Kekurangan: <i>Limited algorithm comparison, minimal hyperparameter optimization, generalization testing unclear, tidak ada multi-dataset validation, feature interactions not explored.</i>	<i>Optuna</i> serta menerapkan <i>SHAP</i> sebagai metode interpretasi utama. Selain itu, penelitian ini juga dirancang untuk menghasilkan model yang lebih stabil melalui evaluasi yang sistematis.
7	<i>Predictive Analysis of Diabetes-Risk with Class Imbalance</i> , 2022 [16]	Penelitian ini menunjukkan bahwa model <i>ANN</i> dengan <i>SMOTE</i> mampu mencapai akurasi 90.2% dan <i>AUC</i> sebesar 0.89. <i>SMOTE</i> terbukti efektif dalam menangani ketidakseimbangan data, sementara teknik <i>Tomek-links</i> memberikan pengaruh yang minimal. Selain itu, ditemukan	<i>SMOTE + Tomek-links + ANN, feature ranking (odds ratio, Boruta, varImp), cost-sensitive learning,</i>	Kelebihan: <i>Multiple imbalance strategies compared, female-specific risk factors identified, actionable clinical insights.</i> Kekurangan: <i>Single gender (female only),</i>	Penelitian ini memperluas pendekatan pada perbandingan algoritma <i>baseline</i> dan <i>boosting</i> . Selain itu, penelitian ini juga mengintegrasikan

No.	Judul dan Tahun	Pembahasan	Metode	Kelebihan dan Kekurangan	Perbedaan Penelitian
		bahwa resistensi insulin dan <i>BMI</i> yang tinggi merupakan faktor risiko utama diabetes, sehingga memberikan <i>insight</i> klinis yang dapat ditindaklanjuti.	<i>female-specific dataset</i>	<i>small dataset</i> , tanpa <i>systematic baseline-boosting comparison</i> , tanpa <i>feature interaction exploration</i> , <i>limited generalizability</i> .	interpretasi model untuk memberikan pemahaman yang lebih mendalam terhadap faktor risiko diabetes.
8	<i>Prediction of Type-2 Diabetes Mellitus Disease Using Machine Learning Classifiers and Techniques</i> , 2022 [14]	Penelitian ini menunjukkan bahwa <i>LightGBM</i> mencapai akurasi tertinggi sebesar 95.20%, diikuti oleh <i>Extra Trees</i> (94.60%), <i>Random Forest</i> (94.80%), <i>Decision Tree</i> (94.40%), <i>Gradient Boosting</i> (94.10%), <i>XGBoost</i> (83.30%), dan <i>Logistic Regression</i> (75.20%). Perbedaan performa hingga 20% menunjukkan bahwa pemilihan algoritma memiliki dampak signifikan terhadap hasil prediksi. Selain itu, algoritma berbasis <i>tree ensemble</i> secara konsisten mengungguli model linear.	7 algorithms (LR, XGB, GB, DT, ET, RF, LGBM), PIDD dataset, 80:20 split, basic evaluation metrics only	Kelebihan: <i>Comprehensive 7-algorithm comparison</i> , <i>practical selection guidance</i> , <i>LightGBM superiority clear</i> . Kekurangan: Tanpa <i>hyperparameter tuning (default parameters only)</i> , <i>minimal feature analysis</i> , tanpa <i>XAI/interpretability</i> , tanpa <i>cross-validation reporting</i> , <i>single dataset (PIDD)</i> .	Penelitian ini menambahkan proses <i>hyperparameter tuning</i> menggunakan <i>Optuna</i> untuk meningkatkan performa model. Selain itu, penelitian ini juga mengintegrasikan pendekatan interpretabilitas menggunakan <i>SHAP</i> .

No.	Judul dan Tahun	Pembahasan	Metode	Kelebihan dan Kekurangan	Perbedaan Penelitian
9	<i>Unveiling diagnostic information for type 2 diabetes through interpretable machine learning, 2025 [30]</i>	Penelitian ini menunjukkan bahwa model <i>DSpaLaRefiner</i> mampu mencapai akurasi 98.79% pada dataset <i>SWMU</i> , 97.22% pada <i>NSMC</i> , dan 97.67% pada data gabungan, dengan validasi eksternal sebesar 91.90%. Model ini mampu mengidentifikasi kasus T2DM bahkan pada kondisi kadar glukosa normal dengan memanfaatkan indikator sekunder. Fitur utama yang berpengaruh meliputi <i>GLU</i> , usia, glukosa urin, <i>HCT</i> , dan <i>HDL-C</i> . Selain itu, model ini mampu mengekstraksi informasi intrinsik seperti rentang nilai fitur yang relevan secara klinis.	<i>DSpaLaRefiner</i> (novel deep learning dengan landmarks + voting), 39 features, 2 hospital datasets (16K+ patients), intrinsic information extraction, comparative algorithms (SVM, RF, MLP, AN)	Kelebihan: <i>Exceptional accuracy</i> (98.79%), <i>both global & local interpretability</i> , <i>clinical feature ranges identified</i> , <i>strong external validation</i> (91.90%), <i>handles normal-glucose cases</i> . Kekurangan: <i>Tabular data only</i> (no images/audio/text), <i>limited to 2 hospitals</i> , <i>binary classification only</i> , <i>algorithm complexity high-reproducibility concern</i> , <i>baseline comparison implicit</i> .	Penelitian ini menggunakan pendekatan yang lebih sederhana namun tetap efektif yaitu menggunakan dan membandingkan algoritma <i>machine learning</i> . Selain itu, penelitian ini lebih menekankan pada kemudahan interpretasi dan implementasi model dalam konteks praktis.
10	<i>Towards Transparent</i>	Penelitian ini menunjukkan bahwa pendekatan AutoML	<i>AutoGluon</i> (AutoML),	Kelebihan: <i>AutoML automation reduces bias</i> ,	Penelitian ini lebih berfokus pada

No.	Judul dan Tahun	Pembahasan	Metode	Kelebihan dan Kekurangan	Perbedaan Penelitian
	<i>Diabetes Prediction: Combining AutoML and Explainable AI for Improved Clinical Insights</i> , 2025 [15]	menghasilkan rata-rata akurasi sebesar 85.01% pada beberapa dataset, yaitu <i>PIDD</i> (76.62%), <i>Sklearn</i> (78.65%), dan <i>Rural African - American</i> (91.36%). Analisis <i>SHAP</i> menunjukkan bahwa <i>Glucose</i> (0.25) dan <i>BMI</i> (0.18) merupakan fitur paling berpengaruh. Selain itu, <i>LIME</i> memungkinkan interpretasi pada tingkat individu, sedangkan <i>Counterfactual Analysis</i> digunakan untuk mengevaluasi skenario hipotetis. Pengembangan aplikasi berbasis <i>Streamlit</i> juga memungkinkan akses yang lebih luas terhadap model.	<i>SHAP</i> , <i>LIME</i> , <i>IG</i> , <i>AM</i> , <i>CA</i> , <i>LightGBM</i> , <i>XGBoost</i> , <i>CatBoost</i> , <i>RF</i> as base models, 5-fold stratified <i>CV</i> , 3 datasets, <i>Streamlit</i> application	<i>comprehensive XAI</i> (5 techniques), <i>strong generalization</i> (3 datasets), <i>interactive clinical tool</i> , <i>balanced performance-interpretability</i> . Kekurangan: <i>PIDD demographic specificity</i> , moderate accuracy (76.62% primary) vs <i>specialized methods</i> , <i>short AutoML training may limit exploration</i> .	perbandingan algoritma <i>baseline</i> dan <i>boosting</i> serta penggunaan <i>Optuna</i> untuk optimasi model. Selain itu, penelitian ini menekankan penggunaan <i>SHAP</i> sebagai metode interpretasi utama untuk menjaga keseimbangan antara kompleksitas dan pemahaman model.

2.2. Landasan Teori

Landasan teori ini menjelaskan konsep-konsep dasar yang digunakan dalam penelitian, meliputi Diabetes Mellitus Tipe 2, *machine learning* dan klasifikasi, algoritma *baseline* dan *boosting*, *hyperparameter tuning* dengan *Optuna*, evaluasi model, serta *Explainable AI* menggunakan *SHAP*.

2.2.1. Diabetes Mellitus Tipe 2

Diabetes Mellitus Tipe 2 (T2DM) merupakan penyakit metabolik yang ditandai dengan tingginya kadar glukosa dalam darah akibat gangguan kerja insulin dalam tubuh [6]. T2DM merupakan jenis diabetes yang paling umum, dengan proporsi sekitar 90–95% dari seluruh kasus diabetes di dunia [7]. Jumlah penderita T2DM terus meningkat dari tahun ke tahun dan menjadi salah satu masalah kesehatan global yang serius karena dapat menyebabkan berbagai komplikasi serta meningkatkan angka kematian [7], [8]. Secara medis, T2DM terjadi akibat adanya resistensi insulin dan penurunan fungsi sel beta pankreas, sehingga tubuh tidak mampu mengatur kadar glukosa darah secara optimal [6]. Resistensi insulin menyebabkan sel-sel tubuh menjadi kurang responsif terhadap insulin, sedangkan disfungsi sel beta pankreas menyebabkan produksi insulin menurun secara bertahap. Kombinasi kedua kondisi ini mengakibatkan kadar gula darah tetap tinggi dalam jangka waktu yang lama.

Kondisi tersebut dapat memicu berbagai komplikasi serius seperti penyakit kardiovaskular, neuropati, gangguan ginjal, serta gangguan penglihatan [8]. Selain itu, T2DM juga dipengaruhi oleh berbagai faktor risiko seperti faktor genetik, usia, obesitas, pola makan tidak sehat, dan kurangnya aktivitas fisik [9]. Beberapa penelitian juga menunjukkan bahwa biomarker tertentu, seperti asam amino dan asam lemak, memiliki hubungan dengan peningkatan risiko T2DM, yang menandakan bahwa penyakit ini bersifat kompleks dan dipengaruhi oleh berbagai faktor biologis maupun gaya hidup [9]. Oleh karena itu, deteksi dini dan penanganan yang tepat menjadi sangat penting untuk mencegah perkembangan penyakit serta mengurangi risiko komplikasi yang lebih lanjut.


2.2.2. *Machine Learning* dan Klasifikasi

Machine learning merupakan bagian dari *Artificial Intelligence* yang memungkinkan sistem komputer untuk belajar dari data dan meningkatkan kinerjanya tanpa harus diprogram secara eksplisit. Istilah *machine learning* pertama kali diperkenalkan oleh Arthur Samuel pada tahun 1959, yang mendefinisikannya sebagai kemampuan komputer untuk belajar secara otomatis dari pengalaman. Seiring perkembangan teknologi, *machine learning* telah banyak digunakan dalam berbagai bidang, termasuk kesehatan, karena kemampuannya dalam mengolah data dalam jumlah besar dan menemukan pola yang kompleks [1].

Dalam bidang kesehatan, *machine learning* dimanfaatkan untuk membantu proses prediksi dan pengambilan keputusan klinis, terutama dengan memanfaatkan data rekam medis elektronik (*Electronic Health Records/ EHR*). Data *EHR* memungkinkan model untuk mempelajari kondisi pasien secara lebih komprehensif, sehingga dapat meningkatkan akurasi prediksi penyakit [2], [3]. Salah satu pendekatan yang umum digunakan dalam *machine learning* adalah *supervised learning*, yaitu metode pembelajaran di mana model dilatih menggunakan data yang telah memiliki label. Pada pendekatan ini, model belajar dari hubungan antara variabel *input* dan *output*, sehingga dapat digunakan untuk melakukan prediksi pada data baru. Salah satu bentuk permasalahan dalam *supervised learning* adalah klasifikasi, yaitu proses mengelompokkan data ke dalam kategori tertentu.

Dalam penelitian ini, *machine learning* digunakan untuk melakukan klasifikasi biner, yaitu menentukan apakah seseorang termasuk dalam kategori penderita T2DM atau tidak. Berbagai algoritma klasifikasi telah dikembangkan dan digunakan dalam *machine learning*, mulai dari algoritma sederhana hingga yang lebih kompleks. Algoritma sederhana atau *baseline* seperti *Logistic Regression*, *Support Vector Machine (SVM)*, dan *K-Nearest Neighbors (KNN)* sering digunakan karena mudah dipahami dan memiliki interpretasi yang baik [10], [11]. Seiring perkembangan teknologi, muncul metode yang lebih kompleks seperti *ensemble learning*, khususnya teknik *boosting* seperti *Gradient Boosting*, *XGBoost*, dan *LightGBM*, yang mampu meningkatkan performa model dengan menggabungkan

beberapa model sederhana menjadi model yang lebih kuat [16], [20]. Pendekatan ini memungkinkan model untuk menangani data yang lebih kompleks dan meningkatkan akurasi prediksi dibandingkan metode tunggal.



Gambar 2. 1 Perbandingan Karakteristik Algoritma *Machine learning*

Gambar 2.1 menunjukkan perbedaan karakteristik antara algoritma *baseline* dan algoritma berbasis *boosting*. Algoritma *baseline* seperti *Logistic Regression*, *SVM*, dan *KNN* umumnya lebih sederhana dan mudah diinterpretasikan, namun memiliki keterbatasan dalam menangani hubungan non-linear yang kompleks. Sebaliknya, algoritma *boosting* seperti *Gradient Boosting*, *XGBoost*, dan *LightGBM* mampu menangani data yang lebih kompleks melalui pendekatan *ensemble*, sehingga cenderung menghasilkan performa prediksi yang lebih tinggi [31].

2.2.3. Normalisasi Data

Normalisasi data merupakan proses transformasi nilai pada fitur numerik ke dalam skala tertentu sehingga setiap variabel memiliki distribusi atau rentang nilai yang lebih seragam. Proses ini bertujuan untuk mengurangi perbedaan skala antar fitur, sehingga setiap variabel memiliki kontribusi yang seimbang dalam proses pembelajaran model [32]. Perbedaan skala yang terlalu besar antar fitur dapat

menyebabkan algoritma *machine learning* menjadi bias terhadap fitur tertentu yang memiliki nilai dominan, sehingga berpotensi menurunkan performa model. Oleh karena itu, normalisasi menjadi salah satu tahapan penting dalam *preprocessing* data sebelum dilakukan proses pemodelan.

Normalisasi umumnya diterapkan pada algoritma yang sensitif terhadap skala data, seperti *KNN*, *SVM*, *Neural Network*, serta metode berbasis *clustering*. Pada algoritma tersebut, perbedaan skala dapat memengaruhi perhitungan jarak atau optimasi model, sehingga diperlukan transformasi data agar berada pada skala yang sebanding [10]. Salah satu metode normalisasi yang digunakan dalam penelitian ini adalah *Standard Scaler* atau standarisasi berbasis *Z-score*. Metode ini mengubah distribusi data sehingga memiliki *mean* sebesar 0 dan standar deviasi sebesar 1. Proses standarisasi dilakukan dengan mengurangi setiap nilai data terhadap rata-rata, kemudian membaginya dengan standar deviasi. Metode ini cocok digunakan pada data yang memiliki distribusi mendekati normal, serta efektif dalam menjaga bentuk distribusi asli data. Rumus *Standard Scaler* ditunjukkan pada persamaan berikut:

$$z = \frac{x - \mu}{\sigma} \quad (2.1)$$

dengan x menyatakan nilai data, μ sebagai *mean* dari data, σ sebagai standar deviasi, dan z merupakan hasil transformasi setelah proses standarisasi [32].

2.2.4. Logistic Regression

Logistic Regression merupakan algoritma klasifikasi berbasis model linear yang digunakan untuk memprediksi probabilitas suatu data termasuk ke dalam kelas tertentu. Algoritma ini menggunakan fungsi sigmoid untuk mengubah *output* linear menjadi nilai probabilitas antara 0 dan 1, sehingga dapat digunakan dalam permasalahan klasifikasi biner [11]. Secara matematis, fungsi sigmoid dapat dinyatakan sebagai berikut:

$$\sigma(z) = \frac{1}{1+e^{-z}} \quad (2.2)$$

dengan $z = w^T x + b$, di mana w merupakan bobot, x adalah fitur atau variabel *input*, dan b merupakan bias. Melalui fungsi ini, *Logistic Regression* memodelkan hubungan antara variabel *input* dan probabilitas *output* secara linear.

Keunggulan utama dari algoritma ini adalah interpretabilitas yang tinggi, karena setiap koefisien dapat menjelaskan pengaruh masing-masing fitur terhadap hasil prediksi. Selain itu, proses komputasinya relatif cepat dan efisien. Namun, *Logistic Regression* memiliki keterbatasan dalam menangani hubungan non-linear serta cenderung memiliki performa yang lebih rendah dibandingkan algoritma yang lebih kompleks pada data dengan pola yang tidak sederhana [10].

2.2.5. SVM

Support Vector Machine (SVM) merupakan algoritma klasifikasi yang bekerja dengan mencari *hyperplane* terbaik yang dapat memisahkan dua kelas dengan margin maksimum. *Hyperplane* tersebut dipilih sedemikian rupa sehingga jarak antara data terdekat dari masing-masing kelas (*support vectors*) terhadap *hyperplane* menjadi maksimal [11], [33]. Secara matematis, fungsi keputusan pada *SVM* dapat dinyatakan sebagai berikut:

$$f(x) = \text{sign}(w \cdot \phi(x) + b) \quad (2.3)$$

dengan w adalah vektor bobot, $\phi(x)$ merupakan transformasi fitur melalui kernel, dan b adalah bias. Penggunaan *kernel trick* memungkinkan *SVM* untuk memproyeksikan data ke ruang berdimensi lebih tinggi sehingga mampu menangani hubungan non-linear.

Keunggulan utama *SVM* terletak pada kemampuannya dalam menangani data berdimensi tinggi serta menghasilkan margin yang optimal, sehingga sering memberikan performa yang baik. Namun, algoritma ini memiliki kelemahan dalam hal waktu komputasi yang relatif tinggi, terutama pada dataset besar, serta membutuhkan pemilihan kernel dan parameter yang tepat agar dapat bekerja secara optimal [10].

2.2.6. KNN

K-Nearest Neighbors (KNN) merupakan algoritma berbasis *instance-based learning* yang melakukan klasifikasi berdasarkan kedekatan jarak antar data. Algoritma ini tidak membangun model secara eksplisit, melainkan menyimpan seluruh data latih dan menentukan kelas suatu data baru berdasarkan mayoritas kelas dari tetangga terdekatnya [14]. Metode *KNN* menggunakan perhitungan jarak, umumnya *Euclidean distance*, untuk menentukan kedekatan antar data, yang secara matematis dinyatakan sebagai berikut:

$$d(x, y) = \sqrt{\sum_{i=1}^k (x_i - y_i)^2} \quad (2.4)$$

dengan x_i dan y_i merepresentasikan nilai fitur dari dua data yang dibandingkan, nilai parameter k merupakan jumlah tetangga terdekat yang digunakan dalam proses klasifikasi. *KNN* memiliki keunggulan karena sederhana, mudah diimplementasikan, dan tidak memerlukan proses pelatihan yang kompleks.

Namun, algoritma ini sangat sensitif terhadap *noise* dan skala data, serta performanya sangat dipengaruhi oleh pemilihan nilai k . Selain itu, *KNN* juga memiliki kelemahan dalam hal efisiensi karena membutuhkan waktu komputasi yang lebih lama pada tahap prediksi, terutama pada dataset dengan ukuran besar [14] [34].

2.2.7. Gradient Boosting

Gradient Boosting merupakan algoritma *boosting* yang bekerja dengan membangun model secara iteratif berdasarkan kesalahan (*residual*) dari model sebelumnya. Pada setiap iterasi, model baru dilatih untuk meminimalkan fungsi *loss* dengan mengikuti arah gradien dari error yang dihasilkan, sehingga prediksi model menjadi semakin akurat [35]. Secara matematis, proses ini dapat dinyatakan sebagai berikut:

$$F_m(x) = F_{m-1}(x) + \gamma_m h_m(x) \quad (2.5)$$

melalui proses iteratif tersebut dapat dinyatakan bahwa $F_m(x)$ merupakan model pada iterasi ke- m , yang diperoleh dengan menambahkan *weak learner* $h_m(x)$ ke

model sebelumnya dengan faktor pengali berupa *learning rate* γ_m . Melalui pendekatan ini, model secara bertahap memperbaiki kesalahan prediksi sebelumnya dengan menambahkan *weak learner* pada setiap iterasi.

Gradient Boosting memiliki keunggulan dalam menangani hubungan non-linear dan pola data yang kompleks, sehingga sering menghasilkan performa yang tinggi. Namun, algoritma ini memiliki kelemahan berupa waktu pelatihan yang relatif lebih lama serta kecenderungan mengalami *overfitting* apabila parameter tidak diatur dengan baik [35].

2.2.8. XGBoost

XGBoost merupakan pengembangan dari *Gradient Boosting* yang dirancang untuk meningkatkan efisiensi dan performa model melalui berbagai optimasi komputasi dan penambahan regularisasi [36]. Algoritma ini tetap menggunakan konsep iteratif berbasis *residual*, tetapi dilengkapi dengan teknik tambahan seperti *parallel processing*, penanganan *missing value* secara otomatis, serta regularisasi untuk mengontrol kompleksitas model. Fungsi objektif pada *XGBoost* dapat dituliskan sebagai berikut:

$$Obj = \sum_i l(y_i, \hat{y}_i) + \sum_k \Omega(f_k) \quad (2.6)$$

fungsi objektif tersebut merupakan kombinasi antara *loss function* l , yang mengukur kesalahan prediksi model, dan komponen regularisasi Ω (*Omega*), yang berfungsi untuk mengontrol kompleksitas model agar tidak terlalu menyesuaikan data latih.

Dengan pendekatan tersebut, *XGBoost* mampu menghasilkan performa yang sangat baik dan lebih stabil dibandingkan *Gradient Boosting*. Keunggulan utamanya terletak pada kecepatan pelatihan, kemampuan generalisasi yang baik, serta ketahanan terhadap *overfitting*. Meskipun demikian, kompleksitas algoritma ini lebih tinggi sehingga membutuhkan proses *tuning hyperparameter* yang lebih intensif dan interpretasi model yang lebih sulit [36].

2.2.9. *LightGBM*

LightGBM merupakan algoritma *boosting* yang dikembangkan untuk meningkatkan efisiensi dalam proses pelatihan model, khususnya pada dataset berukuran besar. Berbeda dengan pendekatan *level-wise* pada *tree tradisional*, *LightGBM* menggunakan pendekatan *leaf-wise tree growth*, yaitu mengembangkan node pada bagian pohon yang memiliki error terbesar sehingga proses pembelajaran menjadi lebih cepat dan efisien [13].

Selain itu, *LightGBM* juga memanfaatkan teknik seperti *Gradient-based One-Side Sampling (GOSS)* dan *Exclusive Feature Bundling (EFB)* untuk mengurangi kompleksitas data tanpa menghilangkan informasi penting. Secara matematis, *LightGBM* mengoptimasi fungsi objektif yang terdiri dari *loss function* dan regularisasi, yang dapat dinyatakan sebagai:

$$V_{j|O}(d) = \frac{1}{n_O} \left(\frac{(\sum_{\{x_i \in O: x_{ij} \leq d\}} g_i)^2}{n_{l|O}^j(d)} + \frac{(\sum_{\{x_i \in O: x_{ij} > d\}} g_i)^2}{n_{r|O}^j(d)} \right) \quad (2.7)$$

dengan $V_{j|O}(d)$ merupakan nilai gain pada fitur ke- j dengan titik split d . Himpunan O merupakan kumpulan data pada node yang sedang dievaluasi, sedangkan n_O menunjukkan jumlah data dalam himpunan tersebut. Nilai x_i menunjukkan data ke- i , dan x_{ij} menunjukkan nilai fitur ke- j pada data ke- i . Simbol g_i merupakan *gradient* dari data ke- i , yaitu nilai yang menunjukkan arah koreksi terhadap kesalahan prediksi model. Selanjutnya, $n_{l|O}^j(d)$ menunjukkan jumlah data dari himpunan O yang masuk ke cabang kiri karena memenuhi kondisi $x_{ij} \leq d$, sedangkan $n_{r|O}^j(d)$ menunjukkan jumlah data yang masuk ke cabang kanan karena memenuhi kondisi $x_{ij} > d$.

2.2.10. *Optuna Framework*

Hyperparameter merupakan parameter yang ditentukan sebelum proses pelatihan model dan sangat memengaruhi performa model [18]. Pemilihan *hyperparameter* yang tidak optimal dapat menyebabkan model mengalami *overfitting* maupun *underfitting*, sehingga diperlukan proses *tuning* untuk

mendapatkan kombinasi parameter terbaik. *Hyperparameter tuning* merupakan proses penting dalam meningkatkan performa model *machine learning*, karena berperan dalam mengoptimalkan cara model belajar dari data [18].

Salah satu metode yang banyak digunakan adalah *Optuna*, yaitu *framework* optimasi *hyperparameter* yang dikembangkan oleh Preferred Networks, Inc. dan diperkenalkan pada tahun 2019 melalui publikasi *Optuna: A Next-generation Hyperparameter Optimization Framework* [37]. *Framework* ini dirancang untuk melakukan optimasi *hyperparameter* secara efisien dan adaptif dalam pengembangan model *machine learning*. Berbeda dengan metode pencarian konvensional seperti *Grid Search* dan *Random Search* yang mengevaluasi kombinasi *hyperparameter* secara statis, *Optuna* menggunakan pendekatan optimasi adaptif berbasis model probabilistik (*Bayesian optimization*). Secara default, *Optuna* memanfaatkan algoritma *Tree-structured Parzen Estimator (TPE)* sebagai metode *sampling* untuk memilih kombinasi *hyperparameter* yang paling menjanjikan berdasarkan hasil evaluasi *trial* sebelumnya [17].

Selain itu, *Optuna* juga menyediakan mekanisme *pruning*, yaitu penghentian lebih awal terhadap *trial* yang tidak menunjukkan performa yang baik, sehingga efisiensi komputasi dapat ditingkatkan. Proses optimasi dalam *Optuna* dilakukan secara iteratif melalui *trial*, yang masing-masing mengevaluasi kombinasi *hyperparameter* tertentu dalam suatu proses yang disebut sebagai *study*. Salah satu karakteristik utama *Optuna* adalah penerapan prinsip *define-by-run API*, yaitu pendekatan yang memungkinkan ruang pencarian *hyperparameter* dibangun secara dinamis saat program dijalankan [37]. Dengan pendekatan ini, pengguna dapat mendefinisikan ruang pencarian secara fleksibel di dalam fungsi objektif menggunakan struktur pemrograman seperti percabangan dan perulangan. Secara umum, proses optimasi *hyperparameter* dapat dinyatakan sebagai berikut:

$$x^* = \operatorname{argmin}_{x \in X} f(x) \quad (2.8)$$

Dalam proses *hyperparameter tuning*, kombinasi parameter dinyatakan sebagai x , sedangkan $f(x)$ merepresentasikan fungsi objektif yang digunakan untuk mengevaluasi performa model berdasarkan kombinasi parameter tersebut.


Beberapa penelitian menunjukkan bahwa penggunaan *Optuna* dapat meningkatkan performa model secara signifikan dibandingkan metode *tuning* tradisional seperti *Grid Search* [22]. Dengan demikian, penggunaan *hyperparameter tuning* yang tepat menjadi salah satu faktor penting dalam menghasilkan model prediksi yang optimal.

2.2.11. Metrik Evaluasi

Metrik evaluasi digunakan untuk mengukur seberapa baik performa model dalam melakukan prediksi terhadap data. Dalam permasalahan klasifikasi, evaluasi model tidak hanya berfokus pada tingkat akurasi, tetapi juga mempertimbangkan kemampuan model dalam mendeteksi masing-masing kelas secara tepat, terutama pada *imbalanced data* [16].

A. Confusion Matrix

Confusion matrix merupakan tabel yang digunakan untuk membandingkan hasil prediksi model dengan nilai aktual [20]. Tabel ini terdiri dari empat komponen utama, yaitu *True Positive (TP)*, *True Negative (TN)*, *False Positive (FP)*, dan *False Negative (FN)*. Gambar 2.2 menunjukkan struktur *Confusion matrix* beserta komponen-komponen penyusunnya.



Gambar 2. 2 *Confusion matrix* dan Performance Metrics

Melalui visualisasi ini, dapat dilihat bagaimana distribusi hasil prediksi model terhadap masing-masing kelas, sehingga membantu dalam memahami jenis kesalahan yang dihasilkan, seperti *false positive* maupun *false negative*.

Berdasarkan nilai-nilai tersebut, dapat dihitung beberapa metrik evaluasi sebagai berikut:

$$\mathbf{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (2.9)$$

$$\mathbf{Precision} = \frac{TP}{TP + FP} \quad (2.10)$$

$$\mathbf{Recall} = \frac{TP}{TP + FN} \quad (2.11)$$


$$\mathbf{F1} = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (2.12)$$

Metrik *accuracy* digunakan untuk mengukur tingkat ketepatan prediksi secara keseluruhan. *Precision* menunjukkan ketepatan model dalam memprediksi kelas positif, sedangkan *recall* mengukur kemampuan model dalam mendeteksi seluruh data positif. Sementara itu, *F1-score* merupakan kombinasi antara *precision* dan *recall* yang memberikan keseimbangan antara keduanya. Pada dataset yang tidak seimbang, metrik seperti *precision* dan *recall* menjadi lebih penting dibandingkan *accuracy*, karena mampu memberikan gambaran performa model yang lebih realistis dalam mendeteksi kelas minoritas [16], [38].

B. Kurva ROC dan AUC

Selain *confusion matrix*, evaluasi model juga dapat dilakukan menggunakan *Receiver Operating Characteristic (ROC) Curve*, yaitu kurva yang menunjukkan hubungan antara *True Positive Rate (TPR)* dan *False Positive Rate (FPR)* pada berbagai nilai *threshold* [21]. Kurva ini digunakan untuk mengevaluasi kemampuan model dalam membedakan antara kelas

positif dan negatif. Gambar 2.3 menunjukkan visualisasi kurva *ROC* beserta nilai *Area Under the Curve (AUC)*.



Gambar 2. 3 ROC Curve dan *AUC*

Melalui kurva ini, dapat diamati bagaimana performa model pada berbagai *threshold* klasifikasi, serta *trade-off* antara *true positive rate* dan *false positive rate* [39].

Nilai *AUC* digunakan sebagai indikator performa model secara keseluruhan. Semakin mendekati nilai 1, maka semakin baik kemampuan model dalam melakukan klasifikasi. Secara matematis, nilai *AUC* dapat dinyatakan sebagai berikut:


$$AUC = \int_0^1 TPR(FPR^{-1}(x))dx \quad (2.13)$$

Nilai *AUC* yang tinggi menunjukkan bahwa model memiliki kemampuan yang baik dalam membedakan antara kelas positif dan negatif pada berbagai *threshold*. Selain itu, teknik *cross-validation* juga digunakan untuk memastikan bahwa model memiliki performa yang stabil dan tidak

bergantung pada satu pembagian data saja [19]. Dengan menggunakan teknik ini, model diuji pada beberapa subset data sehingga hasil evaluasi menjadi lebih *robust* dan dapat digeneralisasikan dengan lebih baik.

2.2.12. Explainable AI

Dalam penerapan *machine learning* di bidang kesehatan, interpretabilitas model menjadi hal yang sangat penting. Model yang memiliki akurasi tinggi tetapi sulit dipahami akan sulit digunakan dalam praktik klinis [23]. Oleh karena itu, *Explainable AI (XAI)* dikembangkan untuk meningkatkan transparansi model sehingga hasil prediksi dapat dipahami oleh manusia [40]. Salah satu metode *XAI* yang banyak digunakan adalah *SHAP (SHAPley Additive exPlanations)*, yang mampu menjelaskan kontribusi setiap fitur terhadap hasil prediksi model [24]. *SHAP* memiliki keunggulan karena dapat digunakan pada berbagai jenis model (*model-agnostic*) serta mampu memberikan interpretasi baik secara lokal (untuk satu data) maupun global (untuk keseluruhan model) [15]. Untuk membantu memahami hasil interpretasi tersebut, *SHAP* menyediakan berbagai bentuk visualisasi yang dapat digunakan untuk menjelaskan kontribusi fitur secara lebih intuitif.



Gambar 2. 4 SHAP Visualizations

Gambar 2.4 menunjukkan beberapa jenis visualisasi *SHAP* yang umum digunakan, seperti *force plot* untuk menjelaskan prediksi pada satu individu (*local explanation*), *summary plot* untuk menunjukkan fitur-fitur paling berpengaruh secara global, serta *dependence plot* yang menggambarkan hubungan antara nilai fitur dengan hasil prediksi.

Secara matematis, *SHAP* didasarkan pada konsep *SHAPley Value* dari *game theory*, yang dapat dinyatakan sebagai berikut:

$$f(x) = \phi_0 + \sum_{i=1}^n \phi_i \quad (2.14)$$

di mana ϕ_i merepresentasikan kontribusi dari fitur ke- i terhadap hasil prediksi, sedangkan ϕ_0 merupakan *base value* atau nilai awal prediksi sebelum mempertimbangkan pengaruh fitur. Melalui pendekatan ini, setiap prediksi model dapat dijelaskan sebagai kombinasi kontribusi dari seluruh fitur yang terlibat.

Dengan adanya visualisasi dan formulasi tersebut, *SHAP* mampu memberikan pemahaman yang lebih mendalam mengenai bagaimana model membuat keputusan. Hal ini membuat model menjadi lebih transparan dan dapat dipercaya, terutama dalam konteks kesehatan yang membutuhkan akuntabilitas tinggi. Namun, meskipun memiliki banyak keunggulan, beberapa penelitian menunjukkan bahwa *SHAP* juga memiliki keterbatasan dalam kondisi tertentu, seperti sensitivitas terhadap distribusi data dan asumsi independensi fitur, sehingga penggunaannya perlu dilakukan secara hati-hati [25].

BAB III

METODE PENELITIAN

Pada bab ini dijelaskan mengenai metode yang digunakan dalam penelitian, meliputi subjek dan objek penelitian, alat dan bahan yang digunakan, serta alur penelitian yang dilakukan secara sistematis.

3.1. Subjek dan Objek Penelitian

Dalam penelitian ini, subjek dan objek penelitian didefinisikan untuk memperjelas ruang lingkup serta fokus kajian yang dilakukan. Pada bidang sains data, subjek penelitian umumnya berupa data, algoritma, atau sistem yang digunakan dalam proses analisis dan pemodelan, bukan melibatkan partisipasi manusia secara langsung.

Subjek dalam penelitian ini adalah dataset diabetes yang digunakan sebagai sumber data utama dalam proses analisis dan pemodelan *machine learning*. Dataset tersebut berisi berbagai atribut yang berkaitan dengan kondisi kesehatan individu, seperti kadar glukosa, tekanan darah, *BMI*, usia, serta variabel lain yang relevan dalam menentukan risiko T2DM. Selain data, subjek penelitian juga mencakup algoritma *machine learning* yang digunakan, yaitu algoritma *baseline* (*Logistic Regression*, *SVM*, dan *KNN*) serta algoritma *boosting* (*Gradient Boosting*, *XGBoost*, dan *LightGBM*).

Sementara itu, objek penelitian dalam penelitian ini adalah performa model *machine learning* dalam melakukan prediksi T2DM. Fokus utama penelitian adalah menganalisis dan membandingkan kinerja berbagai algoritma dalam mengklasifikasikan risiko diabetes, termasuk pengaruh *hyperparameter tuning* terhadap peningkatan performa model, serta bagaimana interpretasi model dapat dilakukan menggunakan pendekatan *XAI*. Dengan demikian, penelitian ini berfokus pada bagaimana kombinasi algoritma, teknik optimasi, dan interpretasi model dapat menghasilkan sistem prediksi yang akurat dan dapat dipahami, khususnya dalam konteks data kesehatan.

3.2. Alat dan Bahan Penelitian

3.2.1. Alat Penelitian

Alat yang digunakan dalam penelitian ini terdiri dari perangkat keras dan perangkat lunak yang mendukung proses pengolahan data serta pemodelan *machine learning*. Adapun rincian alat yang digunakan adalah sebagai berikut:

1. Perangkat Keras

- a. Laptop Asus Vivobook M1403QA
- b. Processor AMD Ryzen 7 5800H with Radeon Graphics
- c. Memori (RAM) 16 GB
- d. Penyimpanan SSD 512 GB

2. Perangkat Lunak

- a. Visual Studio Code sebagai lingkungan pengembangan
- b. Microsoft Word untuk penyusunan laporan penelitian
- c. Microsoft Excel untuk pengolahan data awal
- d. Mendeley sebagai manajemen referensi


3.2.2. Bahan Penelitian

Pada penelitian ini, bahan penelitian yang digunakan yaitu dataset *EHR* yang diperoleh dari kompetisi *Practice Fusion Diabetes Classification* yang diselenggarakan melalui platform [Kaggle](https://www.kaggle.com) pada tahun **2012** sebagai bagian dari *data mining challenge* di bidang kesehatan yang berfokus pada prediksi T2DM. Dataset ini berasal dari Perusahaan Practice Fusion yang menyediakan data rekam medis pasien untuk keperluan analisis dan pengembangan model prediksi penyakit.

Dataset yang digunakan terdiri dari beberapa file utama, yaitu *diagnosis.csv* sebanyak 9.948 data, *medication.csv* sebanyak 9.836 data, *patient.csv* sebanyak 9.948 data, dan *transcript.csv* sebanyak 9.948 data yang berisi informasi terkait kondisi pasien, riwayat pengobatan, data demografis, spesialisasi dokter, serta catatan medis pasien. Data-data tersebut digunakan sebagai fitur dalam proses pemodelan *machine learning* dengan variabel target berupa status diagnosis diabetes.

3.3. Diagram Alir Penelitian

Penelitian ini menggunakan pendekatan *OSEMN* (*Obtain, Scrub, Explore, Model, iNterpret*) sebagai kerangka kerja dalam proses pengolahan data dan pembangunan model *machine learning*. Pendekatan ini dipilih karena mampu menggambarkan alur kerja data science secara sistematis, mulai dari pengumpulan data hingga interpretasi hasil model.



Gambar 3. 1 Diagram Alir Penelitian

3.3.1. *OBTAIN* (Perolehan Data)

Tahap *Obtain* merupakan tahap awal dalam kerangka kerja *OSEMN* yang bertujuan untuk memperoleh data yang relevan dengan tujuan penelitian, yaitu membangun model prediksi T2DM berbasis data *EHR*. Pada tahap ini dilakukan identifikasi sumber data, pemahaman struktur dataset, serta penentuan variabel yang akan digunakan dalam proses pemodelan *machine learning*.

Dataset yang digunakan terdiri dari beberapa file utama yang merepresentasikan berbagai aspek rekam medis pasien. Untuk menghasilkan dataset yang komprehensif, seluruh data diintegrasikan menggunakan atribut kunci *PatientGuid*. Untuk mempermudah pemahaman struktur data, ringkasan masing-masing dataset beserta atribut yang digunakan disajikan pada Tabel 3.1.

Tabel 3. 1 Struktur Dataset

Dataset	Deskripsi	Atribut
<i>patient.csv</i>	Data demografis pasien dan variabel target (deskripsi lengkap disajikan pada Lampiran 1)	<i>PatientGuid, Age, Gender, State, DMIndicator</i>
<i>diagnosis.csv</i>	Riwayat diagnosis berdasarkan ICD-9 (deskripsi lengkap disajikan pada Lampiran 2)	<i>PatientGuid, DiagnosisCount, VisitCount, DiagnosisFreq, AcuteCount, AcuteFreq, Icd9_001-899</i>
<i>medication.csv</i>	Data penggunaan obat pasien (deskripsi lengkap disajikan pada Lampiran 3)	Fitur penggunaan obat pasien yang merepresentasikan konsumsi berbagai jenis obat, dengan jumlah atribut lebih dari 2000 kolom
<i>transcript.csv</i>	Data pemeriksaan klinis (deskripsi lengkap disajikan pada Lampiran 4)	<i>BMI (Mean, Max, Min), SystolicBP, DiastolicBP, Weight, Temperature</i> , serta fitur perubahan

Berdasarkan Tabel 3.1, dapat dilihat bahwa dataset yang digunakan dalam penelitian ini mencakup berbagai aspek rekam medis pasien, mulai dari data demografis, riwayat diagnosis, penggunaan obat, hingga hasil pemeriksaan klinis. Masing-masing dataset memiliki peran yang saling melengkapi dalam merepresentasikan kondisi pasien secara menyeluruh.

Dataset *patient.csv* berfungsi sebagai sumber utama karena memuat variabel target yang digunakan dalam penelitian, sedangkan dataset lainnya berperan sebagai variabel prediktor yang memperkaya informasi pasien. Dengan menggabungkan seluruh dataset tersebut, diharapkan diperoleh representasi data yang lebih komprehensif sehingga dapat meningkatkan kemampuan model dalam memprediksi status T2DM. Selanjutnya, seluruh dataset akan diintegrasikan. Proses integrasi data dilakukan melalui teknik *merging* secara bertahap menggunakan atribut *PatientGuid* sebagai *primary key*, sehingga seluruh informasi pasien dari berbagai sumber dapat digabungkan menjadi satu dataset yang utuh.

3.3.2. SCRUB (Pembersihan dan Penyiapan Data)

Tahap *Scrub* merupakan proses pembersihan dan penyiapan data agar siap digunakan dalam analisis dan pemodelan. Dataset *EHR* umumnya memiliki karakteristik yang kompleks, seperti adanya missing values, data duplikat, serta distribusi kelas yang tidak seimbang. Oleh karena itu, tahap ini menjadi krusial karena kualitas data akan sangat memengaruhi performa model yang dihasilkan. Data yang tidak bersih atau tidak konsisten berpotensi menyebabkan model menghasilkan prediksi yang bias atau kurang akurat.

1. *Data Cleaning*

Proses pembersihan data dilakukan untuk memastikan dataset berada dalam kondisi yang layak digunakan. Tahapan yang dilakukan meliputi pemeriksaan *missing values*, data duplikat, serta konsistensi nilai pada setiap fitur. Pada data *EHR*, *missing values* tidak selalu dapat diartikan sebagai kesalahan, melainkan dapat merepresentasikan kondisi tertentu, seperti pemeriksaan yang tidak dilakukan. Oleh karena itu, penanganan *missing values* dilakukan secara hati-hati.

Dalam penelitian ini, *missing values* diimputasi menggunakan nilai *median* untuk setiap fitur numerik, karena metode ini lebih *robust* terhadap *outlier* dibandingkan *mean* dan tetap mempertahankan karakteristik distribusi data. Selain itu, ditambahkan *missing indicator* pada fitur yang memiliki nilai hilang untuk menandai bahwa nilai tersebut merupakan hasil imputasi, bukan nilai observasi asli. Pendekatan ini dilakukan agar model tetap dapat menangkap informasi keberadaan *missing values* sebagai bagian dari pola data. Selain itu, dilakukan identifikasi dan penghapusan data duplikat untuk menghindari bias akibat pengulangan data, serta pemeriksaan *outlier* yang berpotensi memengaruhi performa model.

2. *Feature Engineering* dan *Encoding*

Pada tahap ini dilakukan transformasi dan penyesuaian fitur agar data dapat digunakan secara optimal dalam proses pemodelan *machine learning*. Proses ini mencakup *encoding* variabel kategorikal serta transformasi fitur numerik. Variabel kategorikal dikonversi menjadi numerik menggunakan metode *one-hot encoding*, terutama untuk fitur nominal seperti jenis kelamin dan kategori diagnosis, karena metode ini tidak memberikan asumsi urutan antar kategori.

Selain itu, dilakukan penyesuaian tipe data pada seluruh fitur agar sesuai dengan kebutuhan model. Untuk fitur numerik, diterapkan proses standarisasi menggunakan metode *StandardScaler* (*Z-score scaling*) untuk menyamakan skala antar fitur. Proses ini penting terutama untuk algoritma yang sensitif terhadap perbedaan skala data seperti *SVM* dan *KNN*. Standarisasi diterapkan pada fitur numerik kontinu seperti usia, *BMI*, tekanan darah, suhu tubuh, serta fitur berbasis jumlah dan frekuensi seperti jumlah diagnosis dan jumlah kunjungan. Sementara itu, fitur kategorikal hasil encoding serta fitur biner seperti *ICD* dan penggunaan obat tidak dikenakan proses standarisasi karena telah berada dalam skala yang seragam. Untuk algoritma berbasis *boosting* seperti *XGBoost* dan *LightGBM*, proses standarisasi tidak menjadi kebutuhan utama. Namun, penerapan standarisasi tetap dilakukan secara konsisten dalam *pipeline*

pemodelan untuk menjaga keseragaman proses antar algoritma serta memastikan perbandingan performa yang lebih objektif.

3. Pembagian Data

Dataset kemudian dibagi menjadi data latih dan data uji menggunakan metode *stratified split* dengan proporsi 70:30, sehingga distribusi kelas tetap seimbang pada kedua subset. Data latih digunakan untuk proses pelatihan dan *hyperparameter tuning*, sedangkan data uji digunakan secara eksklusif untuk evaluasi akhir model. Pemisahan ini penting untuk mencegah terjadinya *data leakage* serta memastikan bahwa model memiliki kemampuan generalisasi yang baik terhadap data baru.

4. Penanganan *Class Imbalance*

Distribusi kelas pada dataset kesehatan sering kali tidak seimbang, di mana jumlah data non-diabetes lebih besar dibandingkan data T2DM. Kondisi ini dapat menyebabkan model cenderung bias terhadap kelas mayoritas. Untuk mengatasi hal tersebut, digunakan teknik penanganan *class imbalance*, baik pada tingkat algoritma maupun tingkat data. Pendekatan yang digunakan meliputi penyesuaian *class weight* pada model serta teknik *oversampling* seperti *SMOTE* untuk meningkatkan representasi kelas minoritas. Pemilihan metode dilakukan berdasarkan hasil evaluasi untuk memastikan bahwa model tidak hanya akurat secara keseluruhan, tetapi juga mampu mendeteksi kelas diabetes dengan baik.

3.3.3. **EXPLORE (Eksplorasi Data)**

Tahap *explore* bertujuan untuk memahami karakteristik data melalui proses *Exploratory Data Analysis (EDA)* sebelum dilakukan pemodelan. Pada tahap ini dilakukan analisis statistik deskriptif dan visualisasi data untuk mengidentifikasi distribusi data, pola hubungan antar variabel, serta indikasi awal faktor-faktor yang berpengaruh terhadap status T2DM. *EDA* menjadi tahap penting karena membantu dalam memahami struktur data secara menyeluruh, sehingga strategi pemodelan yang digunakan dapat disesuaikan dengan karakteristik data yang ada. Dalam

penelitian ini, proses eksplorasi data dilakukan melalui beberapa tahapan utama, yaitu sebagai berikut:

1. Analisis Distribusi Kelas

Analisis distribusi kelas dilakukan untuk mengetahui proporsi antara kelas diabetes dan non-diabetes dalam dataset. Proses ini meliputi perhitungan jumlah dan persentase masing-masing kelas, serta identifikasi adanya *class imbalance*. Hasil analisis ini digunakan untuk menentukan strategi penanganan ketidakseimbangan data serta pemilihan metrik evaluasi model yang sesuai, sehingga model tidak bias terhadap kelas mayoritas.

2. Statistik Deskriptif Variabel

Statistik deskriptif digunakan untuk memberikan gambaran umum mengenai karakteristik data pada setiap variabel. Analisis dilakukan terhadap fitur-fitur utama, khususnya yang berkaitan dengan kondisi klinis pasien, seperti *BMI*, tekanan darah, dan indikator kesehatan lainnya. Statistik yang dianalisis meliputi nilai rata-rata, minimum, maksimum, serta distribusi data. Selain itu, visualisasi seperti histogram dan boxplot digunakan untuk membantu memahami sebaran data dan mendeteksi potensi anomali atau *outlier*.

3. Analisis Hubungan Antar Variabel

Tahap ini bertujuan untuk mengidentifikasi hubungan antara variabel prediktor dengan variabel target yaitu status diabetes, serta hubungan antar fitur. Pendekatan yang dilakukan bersifat deskriptif, seperti membandingkan distribusi variabel pada kelompok diabetes dan non-diabetes, serta mengamati pola hubungan antar variabel. Selain itu, digunakan visualisasi seperti heatmap korelasi untuk melihat hubungan antar fitur. Analisis ini membantu dalam mengidentifikasi variabel yang memiliki indikasi kuat terhadap status diabetes, meskipun tidak digunakan untuk menarik kesimpulan kausal.

3.3.4. MODEL (Pemodelan)

Tahap Model merupakan tahap inti dalam penelitian yang bertujuan untuk membangun model klasifikasi dalam memprediksi status T2DM berdasarkan data *EHR*. Pada penelitian ini digunakan dua kelompok algoritma, yaitu algoritma *baseline* dan algoritma *boosting*, untuk membandingkan performa model sederhana dengan model yang lebih kompleks dalam menangani data kesehatan yang memiliki pola non-linear serta potensi ketidakseimbangan kelas. Algoritma *baseline* yang digunakan terdiri dari *Logistic Regression*, *SVM*, dan *KNN*. Sedangkan algoritma *boosting* yang digunakan meliputi *Gradient Boosting*, *XGBoost*, dan *LightGBM*.

Penggunaan dua kelompok algoritma ini bertujuan untuk melihat peningkatan performa yang dihasilkan oleh pendekatan *ensemble* dibandingkan metode dasar. Algoritma *baseline* digunakan sebagai acuan awal, sedangkan algoritma *boosting* digunakan untuk mengevaluasi peningkatan akurasi dan kemampuan generalisasi model. Dalam proses pemodelan, diterapkan prinsip evaluasi yang valid dengan memisahkan data latih dan data uji secara tegas untuk menghindari data *leakage*. Seluruh proses pelatihan dan *tuning* hanya dilakukan pada data latih, sedangkan data uji digunakan secara eksklusif untuk evaluasi akhir model. Untuk memastikan bahwa proses pemodelan dilakukan secara sistematis dan hasil yang diperoleh dapat dibandingkan secara objektif, penelitian ini dirancang dalam beberapa tahapan pemodelan sebagai berikut:


1. Desain Eksperimen

Desain eksperimen dalam penelitian ini berfokus pada perbandingan performa enam algoritma klasifikasi dalam memprediksi status T2DM. Setiap algoritma dilatih menggunakan dataset yang sama dengan pembagian data yang konsisten agar hasil yang diperoleh dapat dibandingkan secara adil. Seluruh model menggunakan variabel prediktor yang sama, yaitu fitur-fitur yang berasal dari data *EHR* seperti kondisi klinis, riwayat diagnosis, penggunaan obat, serta indikator kesehatan lainnya, dengan target berupa status diabetes. Perbandingan model dilakukan menggunakan metrik

evaluasi yang seragam untuk menentukan algoritma dengan performa terbaik.

2. Pipeline Pemodelan

Gambar 3.2 menunjukkan alur proses pembangunan model *machine learning* yang digunakan dalam penelitian ini untuk prediksi Diabetes Mellitus Tipe 2.



Gambar 3. 2 Machine learning Pipeline untuk Prediksi Diabetes

Proses dimulai dari tahap data *preprocessing*, yang meliputi pembersihan data, penanganan *missing values*, serta normalisasi atau standarisasi data agar memiliki skala yang seragam. Selanjutnya dilakukan *feature engineering* untuk memilih dan mentransformasi fitur yang relevan sehingga dapat meningkatkan kualitas model. Setelah itu, data dibagi menjadi variabel prediktor (X) dan variabel target (Y), kemudian dilakukan pembagian data menjadi data latih dan data uji menggunakan metode *stratified split* untuk menjaga proporsi kelas. Tahap berikutnya adalah

hyperparameter tuning menggunakan *Optuna* untuk menemukan kombinasi parameter terbaik dari masing-masing algoritma.

Proses model *training* kemudian dilakukan menggunakan dua kelompok algoritma, yaitu algoritma *baseline* seperti *Logistic Regression*, *SVM*, dan *KNN* dan algoritma berbasis *boosting* seperti *Gradient Boosting*, *XGBoost*, dan *LightGBM*. Setelah seluruh model dilatih, dilakukan pengujian menggunakan data uji, kemudian dihitung metrik evaluasi seperti *accuracy*, *precision*, *recall*, *F1-score*, serta *AUC-ROC*. Selain itu, digunakan teknik *cross-validation* untuk memastikan bahwa model memiliki performa yang stabil dan tidak mengalami *overfitting*. Berdasarkan hasil evaluasi tersebut, dipilih model dengan performa terbaik untuk selanjutnya dianalisis menggunakan pendekatan *XAI* dengan metode *SHAP* guna mengetahui kontribusi masing-masing fitur terhadap hasil prediksi. *Pipeline* ini diterapkan secara konsisten pada seluruh algoritma untuk memastikan bahwa hasil perbandingan bersifat objektif dan tidak bias.

3. *Baseline Model*

Baseline model digunakan untuk memperoleh gambaran performa awal sebelum menggunakan algoritma yang lebih kompleks. Algoritma yang digunakan adalah *Logistic Regression*, *SVM*, dan *KNN*. *Logistic Regression* dipilih karena memiliki interpretasi yang baik dan sederhana. *SVM* digunakan karena kemampuannya dalam menangani data berdimensi tinggi dan memisahkan kelas secara optimal. *KNN* digunakan sebagai metode berbasis jarak yang sederhana namun cukup efektif dalam beberapa kasus klasifikasi. Ketiga algoritma ini umum digunakan sebagai pembandingan dalam penelitian *machine learning* karena kesederhanaan dan kestabilannya.

4. *Model Boosting*

Selain *baseline*, penelitian ini juga menggunakan algoritma *boosting*, yaitu *Gradient Boosting*, *XGBoost*, dan *LightGBM*. Algoritma *boosting* bekerja secara iteratif dengan memperbaiki kesalahan model

sebelumnya sehingga mampu meningkatkan performa secara bertahap. *Gradient Boosting* membangun model berdasarkan minimisasi fungsi loss secara iteratif. *XGBoost* merupakan pengembangan yang lebih optimal dengan tambahan regularisasi dan efisiensi komputasi. *LightGBM* menggunakan pendekatan *leaf-wise growth* yang membuat proses pelatihan lebih cepat dan efisien, terutama pada dataset besar. Penggunaan algoritma *boosting* bertujuan untuk meningkatkan akurasi dan kemampuan model dalam menangani kompleksitas data *EHR*.

5. *Tuning Hyperparameter*

Untuk mendapatkan performa model yang optimal, dilakukan *tuning hyperparameter* pada masing-masing algoritma menggunakan metode optimasi seperti *Optuna*. Parameter yang dituning antara lain:

- *Logistic Regression*: parameter regularisasi
- *SVM*: kernel dan parameter C
- *KNN*: jumlah tetangga (k)
- *Gradient Boosting*: *learning rate* dan jumlah estimator
- *XGBoost & LightGBM*: *learning rate*, *max depth*, dan jumlah *tree*

Proses *tuning* dilakukan menggunakan data latih untuk menemukan kombinasi parameter terbaik secara efisien.

6. Model Final dan Evaluasi

Model final diperoleh dari hasil *tuning* terbaik pada masing-masing algoritma. Model tersebut kemudian diuji menggunakan data uji untuk mendapatkan performa akhir. Evaluasi model dilakukan menggunakan beberapa metrik, yaitu *Accuracy*, *Precision*, *Recall*, *F1-score*, dan *ROC-AUC*. Selain itu, digunakan teknik *cross-validation* pada tahap pelatihan untuk memastikan bahwa model memiliki performa yang stabil dan tidak mengalami *overfitting*. Setelah model terbaik diperoleh, dilakukan interpretasi model menggunakan pendekatan *XAI*, yaitu *SHAP*, yang diterapkan hanya pada model dengan performa terbaik.

3.3.5. *INTERPRET* (Evaluasi dan Interpretasi Model)

Tahap *iNterpret* merupakan tahap akhir dalam proses penelitian yang bertujuan untuk mengevaluasi performa model serta memahami hasil prediksi yang dihasilkan. Evaluasi dilakukan untuk mengukur kemampuan model dalam mengklasifikasikan status T2DM secara akurat, khususnya pada data yang berpotensi tidak seimbang. Selain itu, tahap ini juga menekankan pentingnya interpretasi model agar hasil prediksi tidak hanya akurat, tetapi juga dapat dipahami, terutama dalam konteks kesehatan yang membutuhkan transparansi dalam proses pengambilan keputusan. Dalam tahap ini, proses analisis dilakukan melalui dua bagian utama, yaitu evaluasi performa model dan interpretasi hasil prediksi menggunakan pendekatan *XAI*.

1. Evaluasi Model

Evaluasi model dilakukan menggunakan data uji untuk memperoleh gambaran performa model terhadap data yang belum pernah dilihat sebelumnya.

a. *Confusion Matrix*

Confusion matrix digunakan untuk mengevaluasi hasil klasifikasi model ke dalam dua kelas, yaitu diabetes dan non-diabetes. Komponen yang dianalisis meliputi:

- *True Positive (TP)*: data diabetes yang diprediksi benar
- *True Negative (TN)*: data non-diabetes yang diprediksi benar
- *False Positive (FP)*: data non-diabetes yang diprediksi sebagai diabetes
- *False Negative (FN)*: data diabetes yang diprediksi sebagai non-diabetes

Analisis *confusion matrix* penting untuk memahami jenis kesalahan yang dilakukan model, terutama dalam mendeteksi kasus diabetes.

b. Metrik Evaluasi

Berdasarkan *confusion matrix*, dihitung beberapa metrik evaluasi utama, yaitu:

- *Accuracy* untuk mengukur tingkat ketepatan prediksi secara keseluruhan
- *Precision* untuk mengukur ketepatan prediksi pada kelas diabetes
- *Recall* untuk mengukur kemampuan model dalam mendeteksi kasus diabetes
- *F1-score* sebagai kombinasi antara *precision* dan *recall*

Dalam penelitian ini, *recall* menjadi metrik yang sangat penting, karena berkaitan langsung dengan kemampuan model dalam mendeteksi pasien yang benar-benar menderita diabetes, sehingga dapat meminimalkan kesalahan *false negative*.

c. ROC-AUC

ROC-AUC digunakan untuk mengukur kemampuan model dalam membedakan antara kelas diabetes dan non-diabetes pada berbagai nilai *threshold*. Nilai *ROC-AUC* yang lebih tinggi menunjukkan kemampuan klasifikasi yang lebih baik. Selain itu, kurva *ROC* juga digunakan sebagai visualisasi untuk melihat *trade-off* antara *true positive rate* dan *false positive rate*.

Selain evaluasi menggunakan metrik tersebut, digunakan juga teknik *cross-validation* untuk memastikan bahwa model tidak hanya bekerja baik pada satu pembagian data saja. Teknik ini membagi data menjadi beberapa bagian (*fold*) dan melakukan pelatihan serta pengujian secara bergantian, sehingga hasil evaluasi menjadi lebih stabil dan mampu merepresentasikan performa model secara lebih umum.

2. Interpretasi Model

Selain evaluasi performa, penelitian ini juga menerapkan pendekatan *XAI* untuk meningkatkan transparansi model. Metode yang digunakan adalah *SHAP*, yang diterapkan pada model dengan performa terbaik. Beberapa visualisasi yang digunakan dalam *SHAP* antara lain:

- *Summary plot* untuk melihat fitur yang paling berpengaruh
- *Dependence plot* untuk melihat hubungan antara fitur dan prediksi
- *Force plot* untuk menjelaskan kontribusi fitur pada prediksi individu

Penggunaan *SHAP* sangat penting karena model *machine learning*, terutama algoritma *boosting* seperti *XGBoost* dan *LightGBM*, cenderung bersifat kompleks. Dengan adanya interpretasi ini, hasil prediksi menjadi lebih transparan dan dapat dipahami oleh pengguna, khususnya tenaga medis.

Output dari tahap ini berupa perbandingan performa seluruh algoritma, penentuan model terbaik berdasarkan metrik evaluasi, serta visualisasi dan interpretasi kontribusi fitur menggunakan *SHAP* pada model terpilih. Hasil tersebut kemudian digunakan untuk menarik kesimpulan mengenai model terbaik sekaligus memberikan pemahaman yang lebih mendalam terhadap faktor-faktor yang memengaruhi prediksi T2DM berdasarkan data *EHR*.

DAFTAR PUSTAKA

- [1] R. K. Manik, D. K. Jain, U. Kaushik, A. Raina, S. B. Takmare, and A. Thorat, "Machine Learning Techniques for Early Detection and Risk Prediction in Chronic Diseases," in *2025 International Conference on Metaverse and Current Trends in Computing, ICMCTC 2025*, 2025. doi: 10.1109/ICMCTC62214.2025.11196523.
- [2] L. Hunik *et al.*, "Diagnostic Prediction Models for Primary Care, Based on AI and Electronic Health Records: Systematic Review," *JMIR Medical Informatics*, vol. 13. 2025. doi: 10.2196/62862.
- [3] J. Wang *et al.*, "Recent Advances in Predictive Modeling with Electronic Health Records," Aug. 2024, [Online]. Available: <http://arxiv.org/abs/2402.01077>
- [4] S. J. Mataraso *et al.*, "A machine learning approach to leveraging electronic health records for enhanced omics analysis," 2024.
- [5] J. E. Gerwer, G. Bacani, P. S. Juang, and K. Kulasa, "Electronic Health Record–Based Decision-Making Support in Inpatient Diabetes Management," *Current Diabetes Reports*, vol. 22, no. 9. 2022. doi: 10.1007/s11892-022-01481-0.
- [6] R. P. Robertson, "Epidemiology and Pathogenesis of Type 2 Diabetes," in *Transplantation of the Pancreas: Second Edition*, 2023. doi: 10.1007/978-3-031-20999-4_3.
- [7] WHO, "<https://www.who.int/news-room/fact-sheets/detail/diabetes>," *World health organization*, 2023.
- [8] L. V. Zhuravlyova, T. A. Rohachova, and O. O. Yankevich, "Cardiovascular autonomic neuropathy in patients with type 2 diabetes mellitus. Review," *Ukrainian Therapeutical Journal*, vol. 2024, no. 4. 2024. doi: 10.30978/UTJ2024-4-68.
- [9] C. Qiu *et al.*, "Novel amino acid and fatty acid signatures linked to type 2 diabetes risk after gestational diabetes mellitus," *Cardiovasc. Diabetol.*, vol. 25, no. 1, Dec. 2026, doi: 10.1186/s12933-026-03144-w.
- [10] M. Fadli Kurniawan and D. Ayu Megawaty, "Comparison of Logistic

- Regression, Random Forest, Support Vector Machine (SVM) and K-Nearest Neighbor (KNN) Algorithms in Diabetes Prediction,” 2025. [Online]. Available: <http://jurnal.polibatam.ac.id/index.php/JAIC>
- [11] V. Sheth, U. Tripathi, and A. Sharma, “A Comparative Analysis of Machine Learning Algorithms for Classification Purpose,” in *Procedia Computer Science*, 2022, vol. 215. doi: 10.1016/j.procs.2022.12.044.
 - [12] I. D. Mienye and Y. Sun, “A Survey of Ensemble Learning: Concepts, Algorithms, Applications, and Prospects,” *IEEE Access*, vol. 10. 2022. doi: 10.1109/ACCESS.2022.3207287.
 - [13] Z. A. Ali, Z. H. Abduljabbar, H. A. Taher, A. B. Sallow, and S. M. Almufti, “Exploring the power of eXtreme gradient boosting algorithm in machine learning: A review,” *Acad. J. Nawroz Univ.*, vol. 12, no. 2, 2023.
 - [14] B. S. Ahamed, M. S. Arya, and A. O. Nancy V, “Prediction of Type-2 Diabetes Mellitus Disease Using Machine Learning Classifiers and Techniques,” *Frontiers in Computer Science*, vol. 4. 2022. doi: 10.3389/fcomp.2022.835242.
 - [15] R. Hasan, V. Dattana, S. Mahmood, and S. Hussain, “Towards Transparent Diabetes Prediction: Combining AutoML and Explainable AI for Improved Clinical Insights,” *Inf.*, vol. 16, no. 1, 2025, doi: 10.3390/info16010007.
 - [16] A. I. Elseddawy, F. K. Karim, A. M. Hussein, and D. S. Khafaga, “Predictive Analysis of Diabetes-Risk with Class Imbalance,” *Comput. Intell. Neurosci.*, vol. 2022, 2022, doi: 10.1155/2022/3078025.
 - [17] S. Dhanka and S. Maini, “A hybridization of XGBoost machine learning model by Optuna hyperparameter tuning suite for cardiovascular disease classification with significant effect of outliers and heterogeneous training datasets,” *Int. J. Cardiol.*, vol. 420, 2025, doi: 10.1016/j.ijcard.2024.132757.
 - [18] Ștefana Duță and A. E. Sultana, “Optimizing Depression Classification Using Combined Datasets and Hyperparameter Tuning with Optuna,” *Sensors*, vol. 25, no. 7, 2025, doi: 10.3390/s25072083.
 - [19] S. S. Bontha, S. K. R. Jammalamadaka, C. P. Vudatha, S. B. Jammalamadaka, B. K. Duvvuri, and B. C. Vudatha, “Predicting Risk and

- Complications of Diabetes Through Built-In Artificial Intelligence,” *Computers*, vol. 14, no. 7, 2025, doi: 10.3390/computers14070277.
- [20] H. Zhang, W. Fan, P. Li, X. Chen, and S. Yin, “Predicting the diabetic foot in patients with type 2 diabetes mellitus based on machine learning,” *Biomed. Eng. Online*, 2026, doi: 10.1186/s12938-025-01494-2.
- [21] X. Liu *et al.*, “An online interpretable machine learning model for predicting cardiometabolic multimorbidity risk in patients with type 2 diabetes mellitus,” *Sci. Rep.*, 2026, doi: 10.1038/s41598-026-36923-2.
- [22] H. El Massari, N. Gherabi, F. Qanouni, and S. Mhammedi, “Diabetes Prediction Using Machine Learning with Feature Engineering and Hyperparameter Tuning,” *Int. J. Adv. Comput. Sci. Appl.*, vol. 15, no. 8, 2024, doi: 10.14569/IJACSA.2024.0150818.
- [23] E. Nasarian, R. Alizadehsani, U. R. Acharya, and K. L. Tsui, “Designing interpretable ML system to enhance trust in healthcare: A systematic review to proposed responsible clinician-AI-collaboration framework,” *Inf. Fusion*, vol. 108, 2024, doi: 10.1016/j.inffus.2024.102412.
- [24] I. Syahrani Tamsir, A. Gautama Putrada, and R. Lingga Wicaksono, “SHAP dalam Explainable AI untuk Deteksi Depresi Mahasiswa Menggunakan AdaBoost,” 2026.
- [25] X. Huang and J. Marques-Silva, “On the failings of Shapley values for explainability,” *Int. J. Approx. Reason.*, vol. 171, 2024, doi: 10.1016/j.ijar.2023.109112.
- [26] K. Syaban and Mardiawati, “Evaluasi Model Ensemble Learning pada Identifikasi Faktor Risiko Diabetes Mellitus,” *J. Teknol. dan Inf.*, vol. 15, no. 2, pp. 121–130, Sep. 2025, doi: 10.34010/jati.v15i2.16238.
- [27] F. Rahman, S. Hossain, J.-J. Tiang, and A.-A. Nahid, “Diabetes Prediction Using Feature Selection Algorithms and Boosting-Based Machine Learning Classifiers,” *Diagnostics*, vol. 15, no. 20, p. 2622, Oct. 2025, doi: 10.3390/diagnostics15202622.
- [28] T. Althobaiti, S. Althobaiti, and M. M. Selim, “An optimized diabetes mellitus detection model for improved prediction of accuracy and clinical

- decision-making,” *Alexandria Eng. J.*, vol. 94, 2024, doi: 10.1016/j.aej.2024.03.044.
- [29] N. M. Nayan, A. Islam, M. U. Islam, E. Ahmed, M. M. Hossain, and M. Z. Alam, “SMOTE Oversampling and Near Miss Undersampling Based Diabetes Diagnosis from Imbalanced Dataset with XAI Visualization,” in *Proceedings - IEEE Symposium on Computers and Communications*, 2023, vol. 2023-July. doi: 10.1109/ISCC58397.2023.10218281.
- [30] X. Lv *et al.*, “Unveiling diagnostic information for type 2 diabetes through interpretable machine learning,” *Inf. Sci. (Ny)*, vol. 690, 2025, doi: 10.1016/j.ins.2024.121582.
- [31] H. M. Deberneh and I. Kim, “Prediction of type 2 diabetes based on machine learning algorithm,” *Int. J. Environ. Res. Public Health*, vol. 18, no. 6, 2021, doi: 10.3390/ijerph18063317.
- [32] I. N. Switrayana, R. Hammad, P. Irfan, T. T. Sujaka, and M. H. Nasri, “Comparative Analysis of Stock Price Prediction Using Deep Learning with Data Scaling Method,” *JTIM J. Teknol. Inf. dan Multimed.*, vol. 7, no. 1, pp. 78–90, Jan. 2025, doi: 10.35746/jtim.v7i1.650.
- [33] T. V. Sai Krishna, S. K. Pathuri, K. S. Sandeep, M. K. Padhi, I. Aswani, and D. Haritha, “An Efficient Machine Learning Classification Model for Diabetes Prediction,” in *Proceedings - 2023 12th IEEE International Conference on Communication Systems and Network Technologies, CSNT 2023*, 2023. doi: 10.1109/CSNT57126.2023.10134615.
- [34] N. Zaferani, M. R. Afrash, and K. Moulaei, “Predicting and classifying type 2 diabetes using a transparent ensemble model combining random forest, k-nearest neighbor, and neural networks,” *Sci. Rep.*, vol. 16, no. 1, 2026, doi: 10.1038/s41598-025-31562-5.
- [35] F. Sigrist, “Gradient and Newton boosting for classification and regression,” *Expert Syst. Appl.*, vol. 167, 2021, doi: 10.1016/j.eswa.2020.114080.
- [36] Z. Arif Ali, Z. H. Abduljabbar, H. A. Tahir, A. Bibo Sallow, and S. M. Almufti, “eXtreme Gradient Boosting Algorithm with Machine Learning: a Review,” *Acad. J. Nawroz Univ.*, vol. 12, no. 2, 2023, doi:

10.25007/ajnu.v12n2a1612.

- [37] T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama, “Optuna: A Next-generation Hyperparameter Optimization Framework,” in *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, Jul. 2019, pp. 2623–2631. doi: 10.1145/3292500.3330701.
- [38] B. Toleva, I. Atanasov, I. Ivanov, and V. Hooper, “An Effective Methodology for Diabetes Prediction in the Case of Class Imbalance,” *Bioengineering*, vol. 12, no. 1, 2025, doi: 10.3390/bioengineering12010035.
- [39] E. R. Susanto and A. Cahyana, “Penerapan Algoritma XGBoost untuk Prediksi Diabetes: Analisis Confusion Matrix dan ROC Curve,” *Fountain Informatics J.*, vol. 10, no. 1, 2025, doi: 10.21111/fij.v10i1.14311.
- [40] H. Baniecki, B. Sobieski, P. Szatkowski, P. Bombinski, and P. Biecek, “Interpretable machine learning for time-to-event prediction in medicine and healthcare,” *Artif. Intell. Med.*, vol. 159, 2025, doi: 10.1016/j.artmed.2024.103026.

LAMPIRAN

Lampiran 1. Deskripsi Dataset *patient.csv*

Variabel	Tipe Data	Deskripsi	Keterangan
PatientGuid	String	Identitas unik untuk setiap pasien yang digunakan sebagai kunci utama dalam proses penggabungan data	ID alfanumerik
Age	Integer	Usia pasien pada saat pencatatan data	0–120 tahun
Gender	Kategorikal	Jenis kelamin pasien	Male, Female, Unknown
State	Kategorikal	Lokasi geografis pasien berdasarkan wilayah negara bagian	Kode state (CA, TX, NY, dll)
DMIndicator	Biner (Target)	Status diagnosis Diabetes Mellitus Tipe 2	1 = Diabetes, 0 = Non-diabetes

Lampiran 2. Deskripsi Dataset *diagnosis.csv*

Variabel	Tipe Data	Deskripsi	Keterangan
PatientGuid	String	Identitas unik pasien	Digunakan sebagai kunci penggabungan data
Icd9_001-139	Biner (0/1)	Penyakit infeksi dan parasit (rentang ICD-9: 001–139)	Menunjukkan keberadaan diagnosis
Icd9_140-239	Biner (0/1)	Neoplasma (rentang ICD-9: 140–239)	Riwayat kanker atau tumor
Icd9_240-279	Biner (0/1)	Penyakit endokrin, nutrisi, dan metabolik	Sangat relevan terhadap diabetes
Icd9_280-289	Biner (0/1)	Penyakit darah dan organ pembentuk darah	Misalnya anemia
Icd9_290-319	Biner (0/1)	Gangguan mental, perilaku, dan perkembangan saraf	Riwayat gangguan psikiatri
Icd9_320-359	Biner (0/1)	Penyakit sistem saraf	Kondisi neurologis

Icd9_360-389	Biner (0/1)	Penyakit mata dan telinga	Gangguan sistem sensorik
Icd9_390-459	Biner (0/1)	Penyakit sistem peredaran darah	Berkaitan dengan hipertensi dan penyakit jantung
Icd9_460-519	Biner (0/1)	Penyakit sistem pernapasan	Gangguan paru-paru
Icd9_520-579	Biner (0/1)	Penyakit sistem pencernaan	Gangguan gastrointestinal
Icd9_580-629	Biner (0/1)	Penyakit sistem genitourinari	Termasuk komplikasi ginjal
Icd9_630-679	Biner (0/1)	Komplikasi kehamilan, persalinan, dan masa nifas	Kondisi obstetri
Icd9_680-709	Biner (0/1)	Penyakit kulit dan jaringan subkutan	Gangguan kulit
Icd9_710-739	Biner (0/1)	Penyakit sistem muskuloskeletal	Gangguan tulang dan sendi
Icd9_740-759	Biner (0/1)	Kelainan bawaan	Cacat sejak lahir
Icd9_760-779	Biner (0/1)	Kondisi yang berasal dari periode perinatal	Kondisi terkait kelahiran
Icd9_780-799	Biner (0/1)	Gejala, tanda, dan temuan abnormal	Gejala non-spesifik
Icd9_800-899	Biner (0/1)	Cedera dan keracunan akibat faktor eksternal	Riwayat trauma
Icd9_E-V	Biner (0/1)	Penyebab eksternal cedera dan klasifikasi tambahan	Kode E dan V
Icd9_Unknown	Biner (0/1)	Kode diagnosis tidak diketahui atau tidak terklasifikasi	Indikator kualitas data
DiagnosisCount	Integer	Jumlah total diagnosis yang dimiliki pasien	Menggambarkan beban penyakit
VisitCount	Integer	Jumlah total kunjungan medis pasien	Tingkat interaksi dengan layanan kesehatan

DiagnosisFreq	Float	Rata-rata jumlah diagnosis per kunjungan	Indikator kompleksitas klinis
AcuteCount	Integer	Jumlah diagnosis akut (kondisi sementara)	Frekuensi penyakit akut
AcuteFreq	Float	Rata-rata diagnosis akut per kunjungan	Tingkat kejadian kondisi akut

Lampiran 3. Deskripsi Dataset *medication.csv*

Variabel	Tipe Data	Deskripsi	Keterangan
PatientGuid	String	Identitas unik pasien	Digunakan sebagai kunci penggabungan data
Medication_1 hingga Medication_n	Biner (0/1)	Indikator apakah suatu obat pernah diresepkan kepada pasien	Contoh: abacavir, abilify, acarbose, aceon, aciphex, acyclovir, adalimumab, adderall, advair, advil, albuterol, aldactone, aleve, allegra, allopurinol, amaryl, ambien, amiodarone, amitriptyline, amlodipine, amoxicillin, ampicillin, anastrozole, androgel, aspirin, atenolol, atorvastatin, azithromycin, furosemide, hydrochlorothiazide, ibuprofen, insulin, lantus, lisinopril, losartan, metformin, metoprolol, naproxen, omeprazole, pravastatin, simvastatin, spironolactone, dan lain-lain
DMIndicator	Biner	Status diagnosis Diabetes Mellitus Tipe 2	1 = Diabetes, 0 = Non-diabetes

Lampiran 4. Deskripsi Dataset *transcript.csv*

Kategori	Variabel	Deskripsi	Relevansi terhadap Diabetes
Anthropometric	Height_Max, Height_Min, Height_Mean, Height_Std	Tinggi badan pasien dalam berbagai nilai agregasi	Digunakan sebagai dasar perhitungan BMI

	Weight_Max, Weight_Min, Weight_Mean, Weight_Std	Berat badan pasien dalam berbagai nilai agregasi	Faktor penting dalam risiko T2DM
	BMI_Max, BMI_Min, BMI_Mean, BMI_Std	Indeks Massa Tubuh (BMI) yang dihitung dari berat dan tinggi badan	Prediktor utama risiko diabetes
	Weight_Change	Perubahan berat badan antar kunjungan	Indikator tren kondisi pasien
Blood Pressure	SystolicBP_Max, SystolicBP_Min, SystolicBP_Mean, SystolicBP_Std	Tekanan darah sistolik dalam berbagai agregasi	Berkaitan dengan risiko hipertensi
	DiastolicBP_Max, DiastolicBP_Min, DiastolicBP_Mean, DiastolicBP_Std	Tekanan darah diastolik dalam berbagai agregasi	Indikator tambahan kondisi kardiovaskular
	SystolicBP_Change, DiastolicBP_Change	Perubahan tekanan darah antar waktu	Indikator perkembangan kondisi kesehatan
Respiratory	RespiratoryRate_Max, RespiratoryRate_Min, RespiratoryRate_Mean, RespiratoryRate_Std	Laju pernapasan pasien	Indikator kondisi kesehatan umum
	RespiratoryRate_Change	Perubahan laju pernapasan	Indikator penurunan kondisi kesehatan
Thermoregulation	Temperature_Max, Temperature_Min, Temperature_Mean, Temperature_Std	Suhu tubuh pasien	Indikator infeksi atau inflamasi
	Temperature_Change	Perubahan suhu tubuh antar waktu	Indikator perubahan

			kondisi kesehatan
Derived Metrics	BMI_Change	Perubahan BMI dari waktu ke waktu	Penting untuk analisis tren risiko diabetes
	Height_Change	Perubahan tinggi badan	Digunakan untuk pengecekan kualitas data